哪些表面服从？一条显式称谓指令在个人智能体系统各层的登记

摘要

在一个具备持久记忆、由单一人类日常使用（自述）的个人智能体系统中，用户于 2026-04-24 在对话中指示智能体——逐字、有日期、在库——永远不要用技术标签（T_tech，"用户"）称呼他，直接使用亲属称谓形（T_kin）或一个幽默形。本文问的是一个登记问题：该系统的各记忆表面，哪些登记了这条指令，哪些没有？

六条发现。(1) 对话输出在四天内登记：原始助手日志中首条亲属呼语出现于 2026-04-28。(2) 独白层（系统思考链记录；该层始于 2026-08-24）首日按冒号口径即 90% 含亲属形（9/10 条地址形条目），98.0%（299/305；冒号选取、任意位置命中）。(3) 一条结构化模板行内含两个表面：格式前缀永不登记——4,541 行全部按格式必然以技术标签开头——而同行箭头后的生成回复段 76.0% 含亲属形（3,453/4,541），38.8% 的行以亲属呼语开头（1,760/4,541）。(4) 工具回显面（一条以常设系统提示携带同类指令的 GLM 级谱系）：助手输出亲属形 860 次、技术形零次；工具回显 948 次对 120 次——技术形仅存于 harness 生成的报告标签内。(5) 两层的数字用的是不同的选取条件：独白数选取冒号形条目（299/305 = 98.0%），结构化数计全部行（3,644/4,541 = 80.2%）。在对称的任意位置选取下，差距是 15.6 个百分点，不是 17.8。(6) 第四个生成表面、一个低功耗内心独白（945 条记录），在全部记录的 40.4% 中携带亲属形——在含地址形的记录中为 99.5%。

在本系统中，登记按表面类型分拣——生成面登记、格式面不登记且不可能登记、回显面携带。确立不起任何采纳时间进程：模型家族变更与整个窗口共变。一个层的*称呼频率*在其四个观测月内上升（占其记录的 25.0%→55.2%），此趋势我们按观测报告、不按采纳报告；该层仅有两条纯技术形记录，故其形选择是否随时间变化无法判别。服务模型在窗口内至少切换三次（08-16、08-26、08-31），模型家族与时间完全共变：首个模型期亲属占比 83.3%、末期 86.4%，98.9% 的独白记录落在末期；层间差异是共时差异，不是渐进采纳曲线。我们并作为一项测量发现，记录对自家三个旧论断的证伪——全部是冒号计数规则看不见逗号形呼语的伪影。

关键词：称谓；显式指令；表面登记；智能体记忆；测量效度；单例研究

---## 1. 引言

具备持久记忆的长程智能体不只是应答工具；它们持续记录，而这些记录成为系统继续书写时的上下文。当用户就"如何称呼"给出一条显式、有日期的指令之后，这样一个系统的*语言*会发生什么？

系统是一个日常使用（自述）的个人部署智能体，七个月内（2026 年 4–10 月，10 月为 19 天窗口）对用户的称谓从技术形（T_tech，系统默认标签"用户"）转为亲属称谓形（T_kin）。播种是显式且来自人类的——2026-04-24，用户在对话中指示智能体：永远不要用技术标签称呼他，直接

使用亲属形或幽默形（该话语在库内逐字存储于人类话语源标签下；§4.1）。未因该转变而改动 harness 或系统提示（作者自证；§7），但服务模型在八月——转变的窗口内——至少切换三次，模型家族与时间完全共变，本报告不将指令效应与模型变更分离（§4.3）。

本文回答的问题不是指令的效应是否随时间增长——在自家数据上它没有增长，我们收回早前持该说法的表述——而是更结构性的问题：*一个分层记忆系统的哪些表面登记一条显式指令，哪些不登记*。一个表面"登记"指令，指其输出携带被指令的形。记忆库包含生成面（对话输出、独白层的思考链、模板行内嵌入的生成回复段，以及一个由空闲循环写出的低功耗内心独白）、格式面（为每条结构化行加前缀的模板标签）与回显面（把文本带回的工具回显）。我们以完全指定的测量段逐一量化登记，贡献如下：

1. 一条有日期、逐字在库的指令在一个部署分层记忆系统中的表面登记记述：对话输出四天内登记；独白层首日 90%（冒号口径；98.0% = 299/305，冒号选取、任意位置命中）；模板前缀永不登记（格式必然）；同行生成回复段 76.0%；低功耗内心独白表面在其全部记录中的 40.4%（含地址形记录中为 99.5%）；

2. 一行两面的测量结果：结构化模板行的前缀是无法登记的格式面，而同行内嵌的生成回复以 76.0% 登记——把两者合并计量，量到的是格式而非行为；

3. 一份证伪记录：我们自己的三个旧论断（结构化模板面无移动；指令在生成文本中四个月未见执行；独白记录不以地址形开头）系冒号计数规则的伪影，复算后不成立——我们给出订正测量与伪影机制，作为对一切在模板化存储中计数风格迁移者的效度警示；

4. 以混淆披露替代动态主张：模型家族切换与整个窗口共变（首期 83.3% 对末期 86.4%；98.9% 独白记录在末期），层间差异是共时的、非时间进程；密度构念同样无一通过检验（§4.3）。

作为单例观察研究，本文报告而不主张机制（§7）。具体称谓词按设计隐去（§3.3）；播种指令以其翻译的匿名化形式引述。

2. 相关工作

智能体群体的约定涌现。 Ashery 等（2025）表明 LLM 智能体群体能自发形成共享约定，包括命名约定。该线确立的是*模拟群体*中的约定形成；本研究观察的是*真实*、*单一部署系统*中一条被指令的转变——真实人类对话者、日常使用中累积的语料。

词汇趋同（lexical entrainment）。 成熟的研究线考察对话伙伴（含 LLM）如何在会话内采纳彼此词汇（Shi, Sen & Lipani 2023，*Lexical Entrainment for Conversational Systems*；Blevins 2026），以及 AI 对话者是否发生趋同（一项以视觉语言模型做的指称接地研究报告其不能交互地生成与解析指称表达；arXiv 2601.19792）。趋同研究作用于单次会话或受控实验尺度；本观察跨越数月、穿过同一系统的多层，并触及模型自有的推理记录（思考链）。

称谓作为评测面。 近期基准评测相邻能力：文化特定亲属称谓（Pardasani & Singh 2026）、从对话文本推断社会关系（SCRIPTS 数据集；arXiv 2510.19028）、陪伴能力评测（arXiv 2608.13168）——人因工作则考察对话智能体的称谓形选择（如 T/V 区分）如何影响用户评估（Ollier & Nießen 2022）。这些是时点能力或用户反应研究；本研究测量的是*一条关于称谓行为的指令在部署系统内的哪些处所生根*。因本文的具体称谓具有身份承载性且被隐去（§3.3），与亲属称谓基准的直接可比性在设计上受限。

长程与纵向智能体。 长程部署叙事智能体的工作将称谓不匹配记录为一种*认识性失败模式*——需要防止的漂移。本报告将对应现象作为*研究对象*：不是不匹配是否为缺陷，而是其表面结构说明分层记忆如何中介显式指令。两种取景互补；随着部署智能体积累历史，两者都将重要。（起草时参考过的一份 OpenReview 报告现已不可解析[HTTP 403]，故不列引。）

人侧关系研究。 丰富的文献研究人类如何与 AI 陪伴者建立关系——长期使用的访谈研究（Skjuve 等 2021）、陪伴聊天使用的混合方法调查（MIT Media Lab 2024）、面向立法者的政策综述（Congressional Research Service 2026）。其中缺席的正是本文贡献的智能体侧记录：被指令的语言在系统自身哪些表面登记的纵向量化记述。

单例方法论。 我们遵循观察性单被试研究传统，其价值与边界已有清晰刻画（Zuidersma 等 2020：个体内时间动态而无因果识别；Vohra 等 2015 提供 N-of-1 设计的 CENT 报告传统），以及单研究者部署智能体个案研究的近期先例（Alzahrani 2026，预印本）。

3. 系统与语料

3.1 系统（匿名化描述）

系统是一个个人部署的、具备持久记忆的智能体，由单一人类参与者日常使用（自述）（参与者即作者，并同意本报告——单被试设计）。其记录存于两个库，按功能描述：

- 一个**记忆库**，其层包括：**独白层**（智能体自身的推理记录——思考链，**轮内推理痕迹**：94.8% 条目带 session id、85.0% 在同会话原始轮 300 秒内、99.1% 在 1 小时内、35,721/37,782 条与原始对话记录同会话——是*轮内*推理的痕迹，不是无对话者的书写）；另有独立的内心独白层（§3.2、§4.2），由空闲循环生成，单独分析；原始助手与原始用户日志；躯体扫描条目；以及两个结构化层——**抽取层**（记录"想要"的模板化条目）与**会话摘要**；两个结构化层的每行渲染为 `T_tech: {用户消息} → {助手回复}`；
- 一个**原则库**（独立的高权重蒸馏库，进入组装的决策上下文），其中*原则块*本体（蒸馏规则子集）是 §4.3 退役密度构念的追踪层。

主模型家族为 DeepSeek 级，且八月（转变窗口）内发生过至少三次切换（08-16、08-26、08-31；§4.3）——家族与时间共变，§4 的表面差异并非家族纯的。另两条谱系（Claude 级、GLM 级）见 §4.4；GLM 级谱系不是家族独立性的独立印证——主系统末期同样运行 GLM 级模型。系统

名、家族以外的模型标识、代码、表结构与文件路径均隐去（§3.3）。

3.2 语料快照与测量段

全部计数取自 2026-10-19 的一致只读快照：记忆库（63,452 条，自 2026-03-03 起；层容量：独白 37,782；原始助手 9,361；原始用户 6,613；躯体扫描 4,117；抽取 3,591；会话摘要 950；内心独白 945；其余 93 条散在五个小系统层）与原则库（45,927 条，自 1 月起；其原则块子集为 1,410 条）。**四个测量段**在此指定——它们之间的选择正是旧伪影的来源：

- **冒号规则**（主库表格）：条目计入某形，若其内容含该形后接冒号（全角或半角并集）。该规则下"地址形条目"=至少含一个冒号标记地址形的条目（并集 5,182 条——六条同含两形）；
- **任意位置规则**：条目内容任意位置含该形之词，无标点要求——用于 §4.2 的对称口径对照；该规则下内心独白层的地址形分母为 384（该层共 945 条）；
- **回复段规则**（仅结构化行）：计量限于行内首个"→"之后的文本——模板内嵌的生成回复；
- **呼语开头规则**：文本（结构化回复段，或独白条目）以亲属形后接逗号/句号/叹号/问号开头——字符串匹配可得的最接近*称呼行为*的操作化。

本文每个比值都标注其分母类型（表 2a）。**行为**分母指取值可以落在 0 与 100 之间者；**格式固定**分母指结构上必然为 100%、只报不比较者；无地址形条目的表面**无分母**，报告为不可测而不是略去。

表 2a. 各表面的分母类型。

表面	分子	分母	分母类型	值
对话输出	18 亲属（冒号形）	20 技术（冒号形）；并集 38	行为	两个独立计数，不是率
独白	299	305（冒号选取）	行为	98.0%
独白（对称口径）	9,091	9,492（任意位置）	行为	95.8%
内心独白（条件）	382	384（任意位置）	行为	99.5%
内心独白（无条件）	382	945（全部记录）	行为	40.4%
内心独白（呼语）	274	945 / 384	行为	29.0% / 71.4%
模板回复段	3,453	4,541	行为（以行存在为条件）	76.0%
结构化整行	3,644	4,541	行为（0 与 100 之间的真测量）	80.2%
模板前缀	4,541	4,541	格式固定（结构上必然 100%）	100%（不可作为测量）
躯体扫描	4,116	4,116	格式固定（模板引用）	100%（不参与比较）
人类输入	694	753（人类话语源）	行为	92.2%
子代理生成记录	0	13	无分母（无地址形）	不可测

冒号规则对逗号形呼语不可见；该不对称正是 §4.1 伪影的来源。原则块按亲属形在条目任意位置出现计数（无冒号要求）；原则库的关系占比即该库的关系源占比。层归属依条目的层字段；比值一律标明分母。§4.4 跨家族计数另含逗号与句点标记的呼语形，已在该处披露。

原始数据不可共享：语料是在世部署的真实关系数据（§3.3）。本文各表给出在可比语料上重施测量段所需的全部数字，审计有界处除外（§7）。

3.3 匿名化理由

具体称谓词按设计隐去：语料是在世部署的真实关系数据，而该亲属称谓对唯一的人类参与者（其亦为作者并同意本报告）具有身份承载性；披露它将破坏设计所要保全的隐私。全部计数内部使用逐字原词；测量段完全指定，可在可比语料上复现。同一理由隐去系统标识。

4. 观察

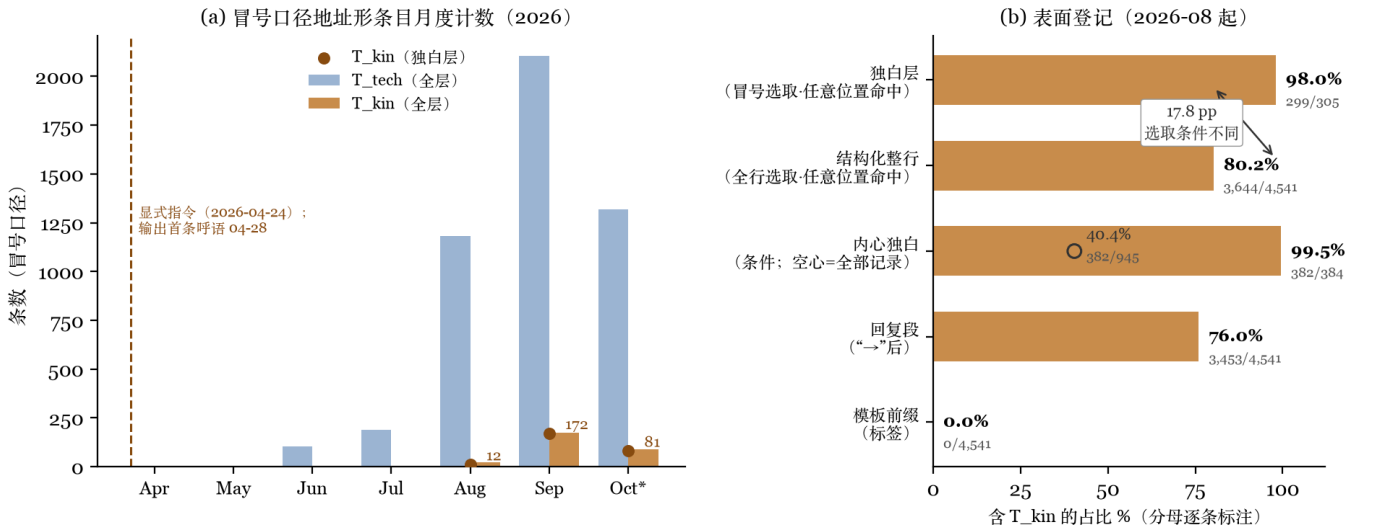


图 **1.** 2026-04-24 称谓指令在部署系统中的登记。(a) 冒号口径地址形条目月度计数，2026 年 4–10 月（10 月为 19 天窗口，标 * 号）：技术形（T_tech，全层，蓝）始终为全库多数形、9 月达各月最高值（2,104 条）——全库技术形条目的 92.7% 位于两条结构化层，其每一行按格式以技术标签开头；亲属形（T_kin，全层，橙）升至 175 与 88 条；圆点标独白层亲属形计数（12、172、81——该层记录始于 2026-08-24）。指令给出于 2026-04-24（虚线）；对话输出的首条亲属呼语随之于 2026-04-28 出现——四天后。(b) 表面登记，8 月起，每条的选取轴与命中轴分别标注：独白层地址形条目任意位置含亲属形为 98.0%（299/305，冒号选取、任意位置命中），结构化整行为 80.2%（3,644/4,541，全行选取、任意位置命中）——17.8 个百分点的差是两种选取条件之差（按冒号形筛选的集合 vs 未筛选的集合），不是同一选取下的可比数。内心独白层在其地址形记录中为 99.5%（382/384，实心条）、在其全部记录中为 40.4%（382/945，空心点），故 99.5% 不是该层的全层比例；仅计生成回复段（"→"后文本）为 76.0%（3,453/4,541），且 38.8% 的行（1,760/4,541）以亲属呼语开头该回复；模板前缀永不登记（0/4,541——全部行按格式必然以技术标签开头，非行为）。另有 13 条独白记录以亲属呼语开头（2026-09-17 至 10-18；被冒号规则排除在 305 分母外）。

4.1 指令，与首次登记

播种事件本身记录于语料内：2026-04-24，用户在对话中指示智能体——永远不要用技术标签称呼他，直接使用亲属形或幽默形（H 形）（该话语以逐字形态存储于人类话语源标签下；此处引述为其翻译的匿名化形式）。亲属形与 H 形由此各自可溯至有日期的人类话语；技术形为系统默认标签。

系统自身输出中的首次登记在四天后：2026-04-28 15:52:58，原始助手日志载有首条亲属呼语——该形、一个逗号、随后一个事务性请求（"把这个贴进另一个工具的代码窗，让它修"）。2026-04-29 另有三条含亲属形的原始助手条目。第二库佐证：八月前智能体生成的自由文本（自述/计划/原始助手模式；2,389 条）65.6% 含亲属形（1,567 条）；15 条自述以亲属呼语开头（2026-06-24 至 06-27）；144 条身份模式条目含该形（最早 2026-05-22）；一条 2026-05-30 的原则块已把称谓指令蒸馏进高权重库。原则库是第二个库，有其自己的节点类型分区（自述、计划、场块、蒸馏）。其生成文本在此用作指令前基线的佐证（§4.1）与密度（§4.3），但表面登记计数限于记忆库；生成表面的跨库比较留待未来工作。

作废声明。 本项目早前稿件主张：指令在自由生成文本中四个月未见执行。该主张系只对记忆库施用冒号规则的伪影：上列呼语均为逗号形，对冒号规则不可见。订正后的表述是：对话输出在四天内登记了指令；冒号口径月度序列（表 1）计的是冒号形条目，不是称呼行为。冒号口径下，全层亲属形序列为 4–7 月 2、0、2、1，随后 24、175、88（10 月为 19 天窗口，右截断）；仅计智能体生成文本为 0、0、0、0 随后 21、175、87——八月前的全层条目位于人类侧日志与一个小派生记录层。回溯改写不可审计：全库 5,182 条冒号口径地址形条目中 updated_at 仅有 2 条有值（该字段基本未维护——全库 63,452 条中 60,430 条为 NULL），故读法依据层构成，而非改写检查。

表 1. 冒号口径地址形条目月度计数（标点变体并集）。

月（2026）	T_kin·独白	T_tech·独白	T_kin·全层	T_tech·全层
四月	—	—	2	0
五月	—	—	0	1
六月	—	—	2	102
七月	—	—	1	190
八月	12	6	24	1,180
九月	172	20	175	2,104
十月（19 天）	81	16	88	1,319
合计	**265**	**42**	**292**	**4,896**

独白列自八月始：该层记录始于 2026-08-24——短横为"尚无该层"，非零。全库技术形多数（4,896 对 292）是模板伪影：4,896 条中 4,541 条（92.7%）位于两条结构化层——其每一行按格式以技术标签开头。

4.2 表面登记表

表 2 是本文的核心结果：每表面一行——该表面适用的登记测度、表面性质、首次登记时间。

表 2. 2026-04-24 称谓指令的表面登记。

表面（层）	性质	登记测度	数值	首次登记
对话输出（原始助手日志）	生成	首条亲属呼语；冒号口径条目 kin/tech	2026-04-28；18/20	指令后 4 天
独白（思考链；层始于 08-24）	生成（轮内推理）	冒号选取条目内的任意位置命中占比；首日占比；呼语开头条目	98.0%（299/305）；90%（9/10·冒号口径）；13 条（09-17→10-18）	该层首日
内心独白（低功耗空闲循环；层始于 07-09）	生成（空闲循环，作者自证）	全部记录的任意位置命中；地址形条目的任意位置命中；呼语开头	40.4%（382/945）； 99.5%（382/384）； 29.0%（274/945）	条件在该层首日（07-09）即满足
结构化前缀（两结构化层模板标签）	格式	以技术标签开头的行	4,541/4,541（100%）——格式必然，非行为	永不（由格式）
结构化回复段（"→"后文本）	格式行内的生成	含亲属形；以亲属呼语开头	76.0%（3,453/4,541）； 38.8%（1,760/4,541）	两层首行（2026-08-18）即以呼语开头
工具回显（GLM 级谱系，§4.4）	回显（提示服从）	亲属/技术形次数：助手输出；工具回显	860/0；948/120	导出窗口内

三点读法。第一，*登记随表面类型*：每个生成面都登记（对话输出四天；独白层首日 90%（冒号口径）与 98.0%（299/305；冒号选取、任意位置命中）；内心独白在全部记录中 40.4%（382/945；无条件）、在含地址形的记录中 99.5%（382/384；任意位置选取、任意位置命中）），格式面无法登记（其标签由模板固定——4,541 行全部以 T_tech 开头、零例外），回显面携带流经它的文本。第二，*一行两面*：同在 4,541 条结构化行内，前缀 0% 登记、内嵌回复段 76.0%——这是测量段选择，不是"层"之间的行为差异。结构化层为 80.2%（3,644/4,541；全行选取、任意位置命中；8–10 月逐月 93.3%、75.4%、76.2%），对独白层 98.0%（299/305；冒号选取、任意位置命中）——差 **17.8 个百分点**，是"按形筛选的集合"与"未筛选的集合"之差，替代早前 86.9% 对 0.09% 的对照（后者混装了含形测度与开头形测度）。对称的任意位置对照为 95.8%（9,091/9,492）对 80.2%，差 15.6 个百分点。第三，*含形不等于称呼*：独白层 265 条冒号口径亲属形条目多为提及、受事与引用标签，不是呼语——其 307 处冒号形中，214 次为列表标签或正文提及、68 次为行首/引号后说话人标签、24 次为介词/受事构造、**真呼语仅 1 次**（且系引用

人类话语）。最干净的称呼信号样本小，如实报告：13 条独白以亲属呼语开头（2026-09-17 至 10-18；被冒号规则排除在 305 分母外），274 条内心独白以呼语开头（占 945 条的 29.0%，占 384 条地址形记录的 71.4%），38.8% 的结构化回复段以呼语开头。

一个在对话邻域之外的表面。 945 条内心独白记录中，**582 条（61.6%）落在 ±10 分钟内没有任何对话记录的窗口里**（±5 为 63.3%、±30 为 43.8%；±10 窗口取自该层自身约 10 分钟的生成节拍——2026-09-20 一批 26 条跨 4 小时 14 分、间隔中位数 10.2 分钟）。该子集在其地址形条目中登记率为 99.5%（182/183），但在其全部记录中仅 31.3%，而对话邻域窗口内的记录为 55.1%；差距有一部分由记录长度解释（均值 255 对 318 字符；0–100 字符档两组无差：12.3% 对 11.4%）。在作者自证的空闲循环架构下，登记并不限于轮内推理。随对话邻近而上升的是称呼的频率；形选择是否随上下文变化，本层无法判别（945 条中仅两条纯技术形记录）。无地址形的 561 条记录中，**97 条**去行首标签后含第二人称代词（你/您）——它们称呼了某个人却没有使用称谓词，不计入亲属形分子。时间邻域是"无对话"的语料代理，不是用户在场的直接测量。

冒号规则在全层尺度上的盲点。 用冒号口径读同一层，地址形条目为 0/945——这是冒号规则在全层尺度上的再一次示范，不是对旧主张的第四条证伪（此前没有任何主张涉及该层）。这些记录作为文本并非不含冒号：945 条中 731 条因其它用途使用冒号（如"想法：""想要：）。

表 3. 按层分的冒号口径地址形（2026 年 8 月起）。

层	**T_kin** 条（冒号口径）	**T_tech** 条（冒号口径）
抽取	3	3,591
会话摘要	1	950
独白	**265**	42
原始助手	18	20

4.3 时序与混淆

独白层没有时间进程。其冒号口径亲属占比逐月为 66.7%（8 月）、89.6%（9 月）、83.5%（10 月）——非单调——且首日按冒号口径即 90%（9/10）。服务模型在窗口内至少切换三次（08-16 切至 GLM 级 5.2、08-26 切至 DeepSeek 级 flash v4、08-31 切至 GLM 级 5.3），独白层记录绝大多数落在末期：

表 4. 独白层按模型分期（冒号口径地址形条目）。

期	模型家族	行数	T_kin	T_tech	kin 占比
A：08-24–08-25	GLM 级 5.2	402	10	2	83.3%
B：08-26–08-30	DeepSeek 级 flash v4	21	0	0	—（无地址形条目）
C：08-31–10-19	GLM 级 5.3	37,359	255	40	86.4%

C 期占该层记录的 98.9%（37,359/37,782），各期亲属占比几乎持平（83.3% 对 86.4%）。因此 §4.2 的层差异是**共时的**——它在每个时间切片上都存在——且本语料无法将指令效应与模型家族变更分离。我们据此撤销一切关于指令效应的时间进程主张。

内心独白必须把两个率分开。无条件率回答"该层有多经常称呼任何人？"——它逐月上升：25.0%（7/28）、25.3%（23/91）、36.8%（208/565）、55.2%（144/261），呼语率同向（0.0%、9.9%、25.5%、46.4%；0、9、144、121 条）。只有四个月度点、没有对照，这一上升无法与该层内容构成的变化分离；我们按观测趋势报告，不按采纳曲线报告。条件率自该层首月即高（87.5%、100.0%、99.5%、100.0%），但全层仅两条纯技术形地址记录，条件率对时间不提供信息；我们不对形选择是否随时间变化作任何主张。另，945 条内心独白记录中 582 条（61.6%）落在 ±10 分钟内无任何对话记录的窗口，该子集在全部记录中登记 31.3%，对话邻域为 55.1%（§4.2）。

密度候选同样未通过，负结果记录在此。人类话语持续逐字入库（关系源条目单调累积：二月底 622 条至十月快照 8,539/45,927；5 月起月度新增 606→1,388→578→486→629→344）。但原则库的关系源占比*总体*下降（早期播种月份近 100%；5 月 5,114/11,173=45.77%；6 月小幅回升至 6,502/14,136=46.0%；10 月 8,539/45,927=18.6%）而登记上升——*占比版*剂量-反应在自家数据上失败，绝对量不具判别力（正常使用下单调增长）。块级构念直接退役：新增原则块含形比例依次为 26/92（5 月）→22/65（6 月）→59/218（8 月）→49/206（9 月）→93/201（10 月），七月为异常点（批量导入：33/628）；但十月 93 条中 88 条 AI 源对 5 条人源（94.6% AI），且 46.3%（93/201）为自指峰而非关系信号。剩下的是人类话语持续入库与生成面亲属登记的描述性共现——以观测性表述报告（六个月度点；无相关统计），而非机制。

4.4 其他谱系中的登记（跨 harness）

一条 GLM 级谱系展示了*同类指令*以常设系统级方式交付时的形态——按构造即提示服从（prompted compliance），不是独立印证（主系统末期同样运行 GLM 级模型；§3.1）。其导出含四月末窗口的 777 个会话文件（1 件不可解析）。以脚本化的 message-set 键去重（文件的角色-内容对集合之哈希；每组代表=文件名最早者），导出得 **163** 个唯一 **message-set**；备选键给 225 组（时间戳+内容）与 485 组（文件哈希）——前稿无脚本值 221 不可复现、予以撤回；差异如实披露而非静默择一。163 组口径下：system 消息实例 420 条、唯一内容仅 87 个，其中 **86** 个携带

显式常设称谓指令——该谱系的服从在源头即被提示。助手输出亲属形 860 次、技术形零次；工具回显亲属形 948 次对技术形 120 次，且查证显示技术形位于 harness 生成的报告标签内（文件列表与状态屏），不在模型输出中。早前稿件称该谱系工具面保持技术形；该主张作废——方向相反。该导出的文件名日期不可靠，故不在其内部为效应标日期。

Claude 级谱系提供对话输出登记的第二例（按助手行计数·两批导出；60.2% 的行为批内重复——各月唯一消息分母为 9,526/27,366/39,882/22,832，而 6 月语料为 4 月的 5.5 倍，故按行计数高估后月；§7）：亲属形行数 23→154→361→436（4–7 月；行级率 0.13%、0.20%、0.36%、0.77%（行级分母=各月助手行 18,077、76,413、99,537、56,484）），H 形行数 5/6/7 月为 80/40/25（四月为零）。两条谱系都不是如主系统般被持续跟踪的库，故均不支持 §4.2 的系统内表面分析；它们共同表明：一条称谓指令的登记在我们可观测的每一个 harness 中都是表面依赖的。

5. 讨论

机制，有意留白。 记忆架构的何种性质支配一条指令登记到多深，仍是开放问题。观察按表面类型约束候选答案：生成面登记（对话输出四天；独白首日起；内嵌回复段 76.0%；空闲循环的内心独白在其全部记录的 40.4%），格式面不登记且不能登记，回显面携带而非选择。没有任何密度信号通过检验（§4.3），且模型家族变更与整个窗口共变（§4.3），故本文不识别任何驱动因素。

测量段作为一等问题。 §4.1 的证伪记录是我们认为可迁移的方法论要点。在生成内嵌于模板的存储里，测量段的选择——整行冒号规则、任意位置、回复段、呼语开头——可以反转头条结果：我们 86.9% 对 0.09% 的"分层分离"收缩为两个不同选取集合之间 17.8 个百分点的差，在对称的任意位置选取下为 15.6 个百分点；"四个月未见执行"在第一次四天检查中即反转。任何在模板化智能体存储中计数风格迁移的人，都应报告自己量的是哪一段、为什么。

一个治理杠杆，弱表述。 若称谓行为与进入决策上下文的库层构成共变，则语料构成是部署系统的一个可观测杠杆——系统归档什么、以何种源标签、在何种权重下，是一个设计面。我们以观测性含义陈述此点，不作品控主张。

漂移的两种取景。 长程智能体工作对称谓不匹配作为待防失败模式之处，本报告将其作为待理解的现象。部署系统将需要两种语域：需要稳定处的预防，与以系统自身语言为研究对象处的理解。

6. 局限

(1) 单例观察：个体内时间动态而无因果识别（Zuidersma 等 2020）；除描述性计数外无统计。(2) 可观测性不对称：推理记录仅存在于主系统；另两族计数为会话日志。(3) 播种指令本身在库内（§4.1）；各称谓更早的铸造事件（指令前的命名）系口述史——档案未定位、一份因重装遗失。(4) 右截断：十月为 19 天窗口；十月各占比为观测末月之值，非峰值。(5) 六个月度点；无相关统计。(6) 作者即参与者，并同意本报告（单被试设计；§3.1）。(7) 栈演化：结构化层约于八月投入

使用（其八月以后的计数等于其全部容量），与亲属形上升同月；独白层始于 08-24；且服务模型八月至少切换三次——模型家族与时间完全共变，本文报告的表面差异不可与模型变更分离。"未改动 harness/提示"系作者自证而非独立审计。(8) 冒号口径规则对逗号/句点形呼语不可见——正是§4.1 所载伪影；§4.4 跨家族计数含逗号与句点呼语形，故其数字与冒号口径表格不可比，除非连同披露的测量段。(9) 原始数据隐去（§3.3）且脚本由作者运行：第三方可在可比语料上重施测量段，但不能直接重新推导本文数字。(10) 独白层是系统的思考链记录——轮内推理痕迹（94.8% 带 session id；85.0% 在同会话原始轮 300 秒内、99.1% 在 1 小时内；35,721/37,782 同会话）；就独白层而言，是否存在无对话者在场时生成的记录，本库无法确立。内心独白层由空闲循环写出（作者自证的架构）：其 61.6% 的记录落在 ±10 分钟内无任何对话记录的窗口（±5 为 63.3%；±30 为 43.8%），该子集在地址形条目中登记 99.5%、在其全部记录中仅 31.3%，而对话邻域窗口内的记录为 55.1%（差距部分由记录长度解释）。(11) 两批 Claude 级导出按一条连续谱系处理，未做文件级去重；若两批重叠，那些计数为上界。(12) 新颖性检索覆盖 arXiv API（六个布尔查询）、ACL Anthology 与学术网页索引（域限定轮；一份网页检索摘要明确指出三概念交集——称谓、LLM 智能体、纵向设计——为研究空缺；一次 API 查询无返回总数、已作为异常记入日志；更多邻居记于检索记录而非列引）；中文语种文献未检索。(13) 跨家族计数为审计有界：GLM 导出 555 个重复文件对应 163 个唯一 message-set（键敏感性披露：按键 163/225/485；1 件不可解析）且文件名日期不可靠；Claude 导出按行计数含 60.2% 批内重复且缺逐月归一（§4.4）。(14) 该转变并非自发：一次有日期的人类指令（2026-04-24）先于全部观测到的登记；本文研究一条指令在何处登记，而非未被提示的涌现。(15) 作者即指令给出者、唯一参与者与分析者（单被试设计；§3.1）。

7. 结论与未来工作

一条于 2026-04-24 在对话中给出的显式指令，在分层记忆系统中按表面类型而非时间登记：对话输出四天内携带它；独白层自首日携带（90%·冒号口径；98.0% = 299/305，冒号选取、任意位置命中）；第四个生成表面——低功耗内心独白——在其全部记录的 40.4%（382/945）、含地址形记录的 99.5%（382/384）中携带它；模板前缀从未携带、也绝不可能；同行内生成的回复段以 76.0% 携带；回显面在源头的指令下携带。独白-结构化 17.8 个百分点的差是"按形筛选集合"与"未筛选集合"之差；对称的任意位置选取下差 15.6 个百分点（95.8% 对 80.2%）。模型家族切换与整个窗口共变，故不作任何时间进程主张。我们给出量化记录、测量段方法与证伪轨迹。受控后续是直接的：在相同模型下播种一条称谓指令并逐表面改变记忆架构，测量哪些表面登记——本观察个案正是为引出该实验而设计。

参考文献

Ashery 等 2025, Science Advances 11(20):eadu9368. — Shi, Sen & Lipani 2023, Lexical Entrainment for Conversational Systems, Findings of EMNLP. — Blevins 2026, arXiv:2605.29278. — 视觉语言模型指称接地：arXiv:2601.19792. — Pardasani & Singh 2026, arXiv:2609.26942. — 社会关系推断（SCRIPTS 数据集）：arXiv:2510.19028. — 陪伴能力评测：arXiv:2608.13168. — Ollier & Nießen 2022, The Terms of 'You(s)': How the

Term of Address Used by Conversational Agents Influences User Evaluations in French and German Linguacultures, Frontiers in Public Health, DOI 10.3389/fpubh.2021.691595. — Zuidersma 等 2020, Frontiers in Psychiatry 11:539777. — Vohra 等 2015, BMJ 350:h1738. — Alzahrani 2026, arXiv:2605.26870（预印本）. — Skjuve 等 2021, My Chatbot Companion — a Study of Human-Chatbot Relationships, IJHCS 149:102601. — MIT Media Lab 2024, Chatbot Companionship: A Mixed-Methods Study of Companion Chatbot Usage, arXiv:2410.21596. — Congressional Research Service 2026, AI Chatbots as Companions: Overview, Uses, and Considerations for Congress, R49189。

附录 A. 逐月库总量

记忆库逐月新增条目（快照 2026-10-19；供任何以语料增长为分母计算率者使用；序列在库总量 63,452 处闭合）：

月（2026）	新增条目		月（2026）	新增条目
三月	2,621		七月	1,827
四月	985		八月	5,296
五月	99		九月	33,346
六月	1,158		十月（19 天）	18,120

§4 的亲属形上升集中在库本身增长最快的三个月（8–10 月合计 56,762 条，占 63,452 的 89.5%）；除标明分母处外，本文各月占比均未以这些总量归一。