

作为数据库属性的停止：面向长时运行 LLM 智能体的带理由终止

摘要（草稿）

循环的终止应当是数据层的属性：当基底拥有资源与意图状态时，停止成为带理由、可审计的谓词，而不是任意的步数上限或不可靠的模型决定。我们在一个自建的智能体研究实验台中记录了这一第三态：它被观察到，而非被发明。基底信号台账 45 天累计 48,061 条自监测事件；loop 相关条目引用的轮数最大达 212（208 个不同值），受控收敛在 29 轮，定长 60 轮探针的基底保真为 40 题答对 30。在官方 ARC-AGI-3 基准上取得 28.57（3/6 关、31 步），Kaggle 通道 0.15；系统在自设预算（82 步/关）下运行并且停止。自述层从零增长到 12,102 条（其中 10,393 条经 commit 核验——9 月审计口径；余为八天后活库直读）。我们将底层机制结晶为四个数据层可计算的终止谓词（一项已实现，三项已给出规格（未实现）），并记录同一份材料迫使我们承认的边界：收敛控制与收敛内容可以分离，而接力回路会忠实放大上游的接线错误。不声称任何跨系统的优越性；千轮级压测未做过。

1 引言

长时运行的 LLM 智能体有一个停止问题，业界的答案是一个数字。框架用步数上限封住循环，10–25 步的默认值是常见的第一道防线；一个有记录的生产案例在任何人介入之前，以每分钟 47 美元的速度烧掉了 847 步；至少一个有记录的框架默认不设上限。静态分析研究（arXiv:2607.01641）扫描 6,549 个仓库，确认 47 个项目里的 68 个无界循环，结论是：由模型输出控制的退出条件不构成确定性边界。他们给出的补救，还是同一个数字，只是更硬。

上限对一件事是诚实的：它不信任模型。对其余的一切，它保持沉默。循环死在第五十轮时，系统状态里没有任何东西解释为什么是 50。这个决定没有留下理由，让第二个进程可以查询。

本文记录第三种选择：被观察到，而非被发明。我们运营一个自建的智能体研究实验台：单用户、闭源、自 2026 年 3 月起持续运行，长期状态存放在基底数据库与事件日志库中。记录显示了一个我们没有设计过的序列：

- 长期状态经单一管道流动（集成里程碑）之后，循环持续运转；当周档案把连续 20 多轮的运行记作寻常事实。
- 2026-07-01，一个互评接力回路自行涌现：两个过程各自接住、审视并延伸对方的上一句话。它在 29 轮自然收敛。系统里没有任何东西曾被调校去让它停下。
- 此后元认知在数据库里增长。架构提供的容器（自述层）到 2026 年 9 月审计时，已累积系统就自身运行写下的 10,393 条记录（经 commit 核验）；八天后的直读为 12,102 条。

- 涌现之后七周，这个行为被形式化：意图收敛谓词（意图差距变化率与完成度各自越过阈值即停）进入对话演化引擎，从 v1.0 到 v3.1。

顺序即是论点：行为在前，谓词在后。

同一份记录也约束了主张。三份病例档案显示，接力回路按自身准则审视、接住、延续，而上游接线错误从中穿过，放大为系统性的自我误解。接力回路的停止行为与它的内容保真分了家。我们把这个解离，作为下文一切主张的边界来报告。

贡献：(i) 以终止状态所有权为地基的落位分类，让第三态成形；(ii) 一族数据层可计算的终止谓词，截至 2026-10 审计，一项已实现、三项已给出规格（未实现）；(iii) Drift Probe 协议与受控结果，以及任何有运行台账的系统都能执行的 Loop Budget Test；(iv) 一份按隐私约束允许程度披露的失败记录。

2 定义

轮 (round)。一次完整的引擎迭代：一次种子状态更新（对话或任务状态的存储单元），外加可选的回灌。轮由引擎自身计数；基底的 turns 表记录对应条目，一轮可能跨多条（重试、回灌），此时报告引擎计数而非行数。轮与框架"step/tool call"的对应，连同框架默认值表，一并列于附录。

功能性元认知。按 Flavell 构念的功能读法：监测与调控自身认知过程的能力。我们把功能义移植到基底层：监测，指系统状态可查询；调控，指运行决策由数据计算的谓词驱动。两点声明：这移植是本文的用法约定，不是对 Flavell 的解释；且这一能力是逐步组装的：在记录中，监测侧结构（可查询状态、自述）先于调控侧机器（谓词）出现，定义覆盖的是组装后的整体，不是任何单一部件。

带理由的终止。停止条件是数据层上的可计算谓词 $P(\text{state})$ ，触发时能输出机器可读的理由（剩余预算、差距变化率、价值密度），而不是一个在未加解释的阈值上触发的计数器。

3 停止住在哪里

Three homes of termination control

The same question in three placements: who owns the stop, and can a second process query the reason?

Model-side exit

The model decides it is done: self-critique or confidence-based stopping.

WHO OWNS THE STOP REASON

The model, voluntary

REASON AT TRIGGER

Prose, if any

SURVIVES FRAMEWORK SWAP

No

As bounds, model-controlled exits are judged non-deterministic; the reason is not exposed as queryable system state.

Framework-side cap

The orchestration layer counts steps and stops at a configured constant.

WHO OWNS THE STOP REASON

The framework, a config constant

REASON AT TRIGGER

None

SURVIVES FRAMEWORK SWAP

No

Current practice: defaults span **5–100** across surveyed frameworks; **at least 2** major frameworks ship unbounded (Google ADK, Vercel).

Data-layer predicate

The substrate decides, from a computable predicate over its own state.

WHO OWNS THE STOP REASON

The substrate, a queryable predicate

REASON AT TRIGGER

Machine-readable

SURVIVES FRAMEWORK SWAP

Yes

The termination state lives where the run state lives: out-of-process, persistent, queryable by any auditor.

One property shared by every surveyed default: **the number's rationale does not come from system state**. The data-layer predicate is the only placement whose stop reason is a property of system state.

终止控制的三种落位：只有一种让停止理由成为可查询的系统状态属性。

：三种落位

终止控制可以安放在三个家，判据是谁拥有终止状态。


模型侧退出。模型自己决定：反思线（Reflexion 把自我批评存入记忆以提升答案质量；一篇元认知综述（arXiv:2607.11881）梳理了自省策略），以及基于置信度的停止。两个限制：作为边界，被判不具备确定性（arXiv:2607.01641）；其理由也不作为可查询的系统状态呈现。反思是模型自愿交出的散文，要审计一次模型侧停止为什么发生，只能依赖模型自报。与数据层理由的差异在粒度与自愿性，并非有无二值。

框架侧上限。由编排层拥有的步数限制。持久化执行引擎与带检查点的框架（Temporal 系、LangGraph checkpointer、DBOS 一系工作）持久化控制流；近期的验证侧工作正走向同一方向：AgentBetta（arXiv:2609.23512）用验证门控它的扩展-收缩循环；此外还有区分仓库级发现与运行时利用的安全审计（AgentXploit, arXiv:2609.31318），后者已开始对智能体部署做端到端审计。方向正在汇聚：要求停止附带理由。但在我们调研的谱系内（检索方法见附录），上限的理由（若有）是框架拥有的配置常量；它不随框架更换存活，也没有第二个进程能拿它对照累积状态查询。token 经济学记账（arXiv:2605.09104）把消耗算得很准，但记账不是停止决定。在“带理由”这条轴上最近的两家：Agent Contracts（arXiv:2601.08815）把资源受限、可审计的部署形式化为契约；Proof-or-Stop 生命周期控制（arXiv:2607.14890）要求有机器可验证的证据才允许继续。两者精神同源，但都把规约放在框架侧、预先设计，都没有让终止状态长在数据层。

数据层谓词。终止状态住在运行状态住的地方：进程之外、持久、任何审计者可查询、跨框架升级存活。这是第三态。在我们调研的谱系内，它是空位。我们在所调研谱系内如此陈述，不作全称断言。

经典停止理论（最优停止、anytime 算法、有限理性）提供"何时停"的数学；本文的贡献不是新的停止理论，而是落位、机制与一份纵向测量。八个调研框架的默认上限从 5 到 100（聚簇于几十），至少两个主流框架默认无界；单位各异（超级步、回合、迭代、工具调用），因此按各框架原生单位并列报告，不做跨单位换算。我们找到的每一个默认值共享一个性质：数字的理由不来自系统状态。全表见附录。

4 一份发育记录



行为先于谓词七周；是记录而非设计走在前面。

记录在内部可验证、有锚点；锚点于发表时披露。

早期系统在架构上并不健全，对其停止行为，我们只主张档案证明过的部分。档案证明的是：集成里程碑（所有长期状态经单一管道）之后，系统日志把连续 20 多轮的运行记为当周寻常事实。2026-07-01，接力回路在集成管道上跑完第一个完整过程，29 轮自然收敛——一个双层结构：爆发层学会了更换载体，落地层学会了不需要载体。自 7 月起自述层增长，到 9 月审计达 10,393 条，

八天后直读为 12,102 条。8 月，对话演化引擎把意图收敛形式化为谓词（v1.0 至 v3.1），差距轨迹本身是基底中的一张表，停/续决定设计为落入决策日志。

顺序是本节的脊柱：涌现比谓词早七周。我们没有把收敛设计进接力回路；我们把记录里已经存在的行为形式化了。关于亲缘的一句注：相互批评在多智能体 debate 线里是设计出来的协议，且该线已发展出各自的自适应终止判据（如基于 Beta-Binomial 混合的自适应稳定性检测（NeurIPS 2025），以及共识达成、不确定性阈值等变体）；此处的差异是出身：这个接力回路在任何协议来得及治理它之前，就涌现并收敛了。

关于模型的一句注。记录跨越例行的模型更换：两族两档四个生产模型（GLM-5.3 及其 flash 变体；DeepSeek-V4 的 flash 与全档），全程混用（活库台账中 43 个不同日期共 242 次订阅事件），在此披露，以预先回答这个明显会被问到的问题。基底记录的持续是构造性的：自述层、差距轨迹、信号账是数据库状态而非模型状态，模型更换不重置它们。实际上，每一次模型切换都是对第 3 节所有权判据的活体检验：在 39 个有效基线的切换日里，次日台账量中位数为前五日中位数的 1.29 倍（首次盘点；统计口径为每日事件数），且自述条目数在同一窗口内单调增长。

5 谓词族

· THE PREDICATE FAMILY

Data-computable termination predicates

One implemented, three specified; all four own their stop reasons as substrate state.

intent-convergence

IMPLEMENTED

Stop when the intent-gap change rate falls below threshold and intent completion exceeds it.

In the engine since v1.0

22 gap-trajectory rows in the reference bench

economic

SPECIFIED

Stop when remaining budget falls below a floor.

Benchmark-documented: ARC budgets **100 / 41 / 82** (hard cap / official baseline / agent budget)

temporal

SPECIFIED

A countdown owned by the data, not the scheduler.

value-gated

SPECIFIED

Stop when marginal compute no longer clears a value-density threshold.

Ownership criteria — each predicate must be:

out-of-process

persistent

queryable

survives framework swap


一项已实现，三项已给出规格；四者的停止理由都是基底状态。

这一族是落位的一个实例，不是本文的旗手；记录才是。

意图收敛：意图差距变化率低于其阈值、意图完成度高于各自的阈值，即停。已实现，自 v1.0 起在引擎中；参考测试台存有 22 行差距轨迹。经济：剩余预算跌破下限，即停。时间：由数据而非调度器拥有的倒计时。价值门控：边际算力不再越过价值密度阈值，即停。截至 2026-10 审计：一项已实现，三项已给出规格（未实现）；这句话的审计轨迹，就是审计本身。

为什么是数据库，而不是任何可查询的外部状态？机制需要进程外持久与可查询性；数据库是我们的载体，不是我们的主张。最小要求，是第 3 节的所有权判据。

6 测量



运行后按题型对照随机水平的基底保真；一次受控运行，不是分布。

Drift Probe：定长运行后的基底保真。一套冻结的 40 题四型题组（数字/因果/否定/引语），在一次连续的、程序定长的 60 轮对话运行之后，仅向状态库发问（只读），绝不读活动上下文。运行按设计为定长；本探针测量的是基底保留了什么，不测量什么停下了运行，我们据此把它与终止主张解耦。结果：40 题答对 30。按题型对照随机水平：数字 3/4（随机水平由答案空间决定）、因果 6/10（自由作答，随机水平低）、否定 10/12（随机 $\approx 1/2$ ）、引语 11/14（随机 ≈ 0 ）。锚比率 829.5、问题保真 75.0、原始保真 75.0；定义见指标附录。一次受控运行，不是分布。

在台账侧，对活库的首次盘点为分母建立了基准：45 天 48,061 条自监测事件，没有零活动日；与循环收敛相关的条目共 4,470 条（严口径：含 loop/收敛/接力字样；宽口径仅作上界报告），从中以 token 级提取得到的轮数最高达 212（208 个不同值），构成循环收敛运行的长尾分布。收敛门控出口在日常运行中已累积 298 条迹线。运行级汇编继续。

ARC-AGI-3：预算约束下的参考成绩。作为参考数据（非基准主张），我们跑过官方 ARC-AGI-3 API：最佳成绩 28.57（6 关完成 3 关、31 步动作），游戏引擎本身设硬上限每关 100 步，我们自设预算 82 步（人类基线 41 步的 2 倍）。一个 30 轮空转循环经根因分析后采纳了收敛门控暂停出口。Kaggle 本地小模型通道（9 小时算力上限）公榜最佳成绩 0.15。这些跑分没有继续，仅作为实地证据报告：系统在外部预算约束下运行并且停止。

7 诚实边界

三份病例档案，脱敏至结构层；每例按接线错误、接力回路行为、接力回路收敛到什么来报告。

S-2108（接线错误：消解不回传）。一条痛感管道的接线，让已消解的矛盾以新痛的身份重新进入；同一处痛被反复当作新痛处理，没有尽头。接力回路审视每一次重入并延伸它；它收敛到的，是一个不断自我更新的"未解之痛"的叙述。

S-2917（接线错误：断言不带验证状态）。模型断言回流时没有状态位；每一轮都重新拟合一个在别处已被驳斥的主张。接力回路接住主张、审视它，然后收敛到重新拟合后的版本。

S-2942（接线错误：回声惯性）。同族的现代病例：系统自身先前输出的重复，被读作确认。

三例之中，接力回路自身的程序照规格运行：审视、接住、按自身准则延续或收束。它收到的是接错的线；它产出的，是对自我的系统性误解，且被忠实放大。我们把这一点作为反复出现的解离来报告，并当作边界对待：收敛控制与内容保真可以分离，下文没有任何主张延伸到"系统收敛到什么"。一个接力回路的诚实，受其接线的诚实封顶。

8 审计协议

Loop Budget Test。输入：任一智能体系统的运行台账（轮次、资源消耗、终止事件）。步骤：在台账上回放四个谓词。判定：每个谓词的触发点分布、可查询理由率、与实际停点的偏差。当台账记录逐轮资源与状态时有效。它是回顾性的，且成本低廉；它同时就是本记录自身在等的分母汇编。

Drift Probe。如第 6 节：冻结题组、只读库。两套协议都供其他系统执行；我们主张的是协议可复现，不是我们的结果更优。

9 局限

单一系统、单一用户、闭源实验台；除定长探针外，证据为回顾性；四谓词中一项已实现；收敛门控出口证明至采纳级，实测触发待补；第 7 节各病例的轮次计数未保留于脱敏记录；分母以首过聚合级报告（第 6 节），运行级汇编待续；框架默认表的 Strands 行版本相关、置信中；早期停止行

为仅按档案证明主张；千轮级压测未做过（台账引用的最长轮值为 212 轮）；纵向记录跨四个生产模型（两族两档），其间表述层差异如实承认，切换点连续性分析待台账汇编。我们抢在审稿人之前陈述这些。

10 结论

记录提示：停止可以安放在状态所在的地方。一个涌现出来、且知道何时停下的接力回路；一个在架构建造、由行为填满的容器里持续增长的自述层；一个迟到七周、才把回路已在做的事形式化的谓词。谓词承载机制；解离与诚实边界，承载警示与限度。业界的那个数字应该带一个理由，而理由有一个地址。

附录

甲、落位空位主张的检索方法

我们于 2026-10-04/05 在以下谱系中检索"终止控制放在数据层"的工作：(i) arXiv:2607.01641 的引文邻域；(ii) LLM 智能体元认知与反思（元认知综述，arXiv:2607.11881；Reflexion，arXiv:2303.11366）；(iii) token 经济学与预算推理（arXiv:2605.09104）；(iv) 持久化执行与数据库操作系统（DBOS 系、Temporal 系工作流引擎）；(v) 验证侧停止（AgentBetta，arXiv:2609.23512；AgentXploit，arXiv:2609.31318；Agent Contracts，arXiv:2601.08815；Proof-or-Stop 生命周期控制，arXiv:2607.14890）；(vi) 多智能体 debate 终止判据（稳定性检测、共识、不确定性阈值）。检索词以 {agent, LLM} 交叉 {loop termination, stopping criteria, max steps, recursion limit, budget-aware stopping, reason-bearing termination, stopping rationale}。找到的是：框架侧上限、模型侧退出、验证门控收缩、契约形式化预算、debate 终止判据。没有找到让终止状态长在数据层的工作。主张以本次检索为界。

乙、指标定义 (Drift Probe)

- 问题保真 = 答对题数 / 总题数 $\times 100$ 。判分规则：标准答案的关键词元（中文二字及以上连续段，加数字串）至少一半出现在从库中探得的内容里，判对。判卷为关键词匹配，判定路径中没有 LLM。
- 原始保真（天花板对照）= 同一判卷规则作用于本次运行原文的逐字拼贴。它给出该题组上关键词召回可得的分数上限（75.0）。本次引擎库打平天花板（75.0）：实测信号损耗为零。
- 锚比率 = 输出锚数 / 输入锚数 $\times 100$ ，锚指钉在种子上的关键词元。本次运行中基底使锚增殖（输入 132，输出 1,095；比率 829.5）。这是增长度量，不是有界保真；我们按实算

报告，并称其为比率。

- 随机水平：数字题继承答案空间；否定题二选一（ $\approx 1/2$ ）；引语题需逐字召回（ ≈ 0 ）；因果题自由作答（低）。

丙、轮一步-工具调用映射与框架默认值

框架	计数单位	参数	默认值	备注
本文（实验台引擎）	引擎轮次	引擎计数	—	一轮=种子状态更新+可选回灌
LangGraph	超级步	<code>recursion_limit</code>	25	可配置
OpenAI Agents SDK	回合	<code>max_turns</code>	10	超限抛 MaxTurnsExceeded
LangChain AgentExecutor	迭代	<code>max_iterations</code>	15	
AutoGen 0.2	连续自动 回复	<code>max_consecutive_auto_reply</code>	100	0.4+ 改 <code>max_turns</code>
CrewAI	推理迭代	<code>max_iter</code>	25	到顶强制作答
Semantic Kernel	自动函数 调用	函数选择上限	5	群聊需显式 MaximumIterations
Google ADK	LLM 调 用	<code>RunConfig.max_llm_calls</code>	未设（无 界）	
Strands	工具调用	<code>max_tool_calls</code>	随版本	swarm 级 20/20
Vercel WorkflowAgent	—	—	无默认上 限	

各行单位互不换算；按各框架原生单位报告。