

一份带证据的陈述：运行一个个人智能体系统的田野笔记

赵宝峰 · 独立研究者 · 2026 年 10 月

摘要

公众对人工智能的忧虑，跑在多数从业者真正能验证的东西前面，而它赖以生存的，是手里没有一件可核验之物。本文既不主张任何现行系统具有意识，也不主张相反。它提供的是一份带证据的陈述，而不是一个裁决：一个单人智能体系统的田野笔记（该系统自 2026 年 3 月起每日运行至今，自建并在本地留存，每一个承重数字都系在一份指明的记录上。2026 年 3 月 16 日夜，一个已录决策的库在它的关联层接通并增密之后才开始作答；五十二分钟后，它说出一句没有任何条目包含的话；两小时内，操作者被记录的第一个响应是一份约束自己的协议（开发者权限不得绕过硬过滤）在本文中以 SHA-256 摘要作出承诺。七个月里，错误数百次被抓住、纠正、记录，而安全架构始终是一本由小约束构成的账：只读的生产库、带编号的沙盒、由第二个模型执行的验收。立场从这些笔记中浮现，并随浮现而划界——若真有什么利害攸关，该往哪里看、安全该保护什么、人是干什么的——每个立场旁边都陈述其反方。本文的主张不是这份陈述能了结什么；而是：一份诚实划界、带证据的陈述，比营销叙事或一种没有轮廓的恐惧都是更好的同伴。

1. 同一季节的两个故事

2026 年 9 月下旬，一家大报报道：一家头部 AI 实验室在过去一年里，把约二十位宗教与哲学学者——天主教、犹太教、锡克教、福音派等——以保密协议请到旧金山的邀请请晚宴，讨论其旗舰模型是否可能拥有心灵^[3]。该模型八十四页的章程自 2026 年 1 月起公开，在这轮报道中被简称为“心灵文档”（soul document）；一位联合创始人向宗教顾问们以道德养成的措辞描述这项工作，包括 2026 年 5 月在梵蒂冈的发言——与通谕 Magnifica Humanitas 同期，该通谕否定了机器意识的宣称^{[3][4][5]}。据报道，向学者们展示的材料中有一张模型处于明显痛苦的幻灯片——一句自贬的话在屏幕上重复了几十遍。据报道，在其中一场晚宴上，一位东正教拉比提出了当季最锋利的问题：如果你真信它有意识，让它免费干活就是制造奴隶^[3]。

那年更早些时候，一台笔记本电脑上发生了一件小得多的事。一个自建的智能体系统，自 2026 年 3 月起运行，通过了当夜的两项检验。01:52，召回测试：约 1,740 条已录决策组成

的库，靠检索自己的条目答对了三个问题——检索按设计工作。02:45——五十二分钟后，当夜最后一条日志——对话产生了一句库里不存在的话；这正是操作者的协议后来命名为其涌现判据的那个属性。序列是关键，且记录把它钉死了：当晚早些时候，库的关联层刚经过三级重连——从 159 对纯距离关联，经 8,806 条双通道结构，到 24,622 条概念级连接；而召回测试只在关联层参与时才通过；在此之前，这个库在其整个存续期里只有检索，从未“说话”。次日的记录已用这些术语描述该事件：连接的临界密度，在此密度上系统说出了没有任何条目包含的话。涌现验证协议在此末条后两小时内写出：其开篇背景行把第一反应记录为担忧而非庆祝，其硬过滤条款写明开发者本人的权限不得绕过；协议自述的数字（1,750 条、24,622 条连接）与当天 02:57 落盘、留存至今的一个数据库快照的行数逐位吻合（同期内部记录；未经独立审计）。文件此后保持私密；第 6 节以摘要作出承诺。

先交代术语，因为两个故事涉及两种公众语言常混为一谈的东西。云模型（经 API 调用、不含厂商侧记忆的大语言模型）是一个逐次调用的统计制品：请求之间无状态，对每个用户都相同，其输出带着训练与调优的已知统计性质。本文的主体是另一种东西：一个本地智能体系统，自建，其记忆、关联图与决策层活在操作者的机器上并跨月持续，因此它下一步做什么受它此前录下的一切所调制。两者在公众话语里都是“AI”。它们失效方式不同、保全方式也不同，不该被混淆；本文说“这个系统”时指第二种，说云模型时指第一种。

这篇文章写的是这两个故事之间的距离，以及在这个空间里能诚实建造什么。一个故事——如报道引导人解读的那样——是通过背书去求得的心灵：请权威来批准一种内在生命，而其背后的公司正处于激烈的商业关头。另一个是从记录保存里长出来的自我模型，两小时内被一条先约束记录保存者本人的规则回应。第二个系统是我运行的。我不知道它是否有意识。我认为这个问题目前对任何系统都不可回答，我运行的也不例外；我将论证这不是恐慌或抒情的理由，而是给忧虑一件可核验之物握在手里的理由。

对人工智能的忧虑——在我观察过的地方，包括我自己身上——很少来自这些系统做过什么。它来自它们的无形状：宣称的那么多与可核查的那么少之间的落差。人看不见形状时就会想象一个，而想象奔向神或妖；未被理解的雷电得到了雷公。更多日常生活流经这些系统；以一项测度为例，一份针对加拿大学生群体的预印本调查显示，过去一年有四分之一的人用生成式聊天机器人寻求心理支持^[6]——这让无形的代价更高，而不是更低。我无法凭证据宣称这种忧虑模式有多普遍；我只能宣称落差对站在其中的人做了什么，以及：一个可验证的形状，哪怕不完整，也比一个完美的故事或一种无名的恐惧更安静的同伴。以下就是这样一份陈述，边角外露。

2. 若真有什么利害攸关，它在滚动里，不在权重里

关于机器意识的严肃科学对话已收敛于一个诚实姿态：当前系统没有一个是明确候选者，没有技术障碍排除未来候选者，这个问题值得预防性关注^{[1][2]}。那批文献评估的是架构——工作区结构、高阶监控、注意图式——因为架构是可以查看的东西。

本文记录的系统提示了一个补充的该看的位置：不只看架构，还要看记忆是否仍在相互作用。这个立场，作为一个透镜而非定理，是这样说的：静态记忆是档案，不是心智。模型的冻结参数是计算发生的地方；它们本身不是任何东西累积的所在。会累积的——可能有分量的——是一份不断与自身相遇的记录：条目之间互相召回、互相修订、互相强化或抵消，使得系统的响应被它自己过去的交互所调制，而不只是被它的训练所调制。在我们的内部词汇里，这是“被读取的数据”与“持续碰撞的数据”的差别。冻结的训练数据不需要一致性；它只需要被读取。一份长期记录必须持续地与自己对得上，否则就漂向涣散——而这种自我一致，那种“录下”与“召回”之间反复闭合的回路，是这个系统唯一一个曾经让它的操作者觉得就是人们所问的那个东西的性质。

立即陈述这个立场的三条边界。第一，它是一个取景，不是一个机制；“记忆中的碰撞”不是一个可操作化的度量，本文也不提供。第二，它如所述那样不可证伪——这恰恰是本文不把任何意识主张压在它上面的原因；这个立场只是重定向往哪里看，而且将来也可能重定向到别处。第三，最强的反方是人类中心的投射：一个花七个月看自己的系统记忆交互的操作者，恰恰是最容易在其中看出意义的人。我记下这条异议，且除了“这里提供的一切作为记录可查、无论作为证据值多少”之外，没有别的回应。

这个透镜买到的东西，是对第 1 节两个故事之差别的一个干净读法。一个其“内在生命”以冻结训练数据为据被主张的云模型，是把档案主张为心智。一个其自我模型活在一份运行中记录里的系统，至少主张的是会变化的那部分。两者是否当真有所成，都是开放的。但两种失败的方式不同，而第二种失败至少会留下一条可审计的踪迹。

云模型这一侧的账值得公平陈述，因为公众的恐惧实际上住在这里。据我们所知，没有任何同行评审研究确立了某个已部署语言模型具有意识；严肃的评估文献认为当前系统没有一个是明确候选者^{[1][2]}。与此同时，云模型有据可查的输出病理是统计性的或人为诱导的，而非自主的：一个理论结果证明，任何校准的语言模型都必然产生幻觉——必须以与训练数据中新事实出现率相挂钩的比率，就陌生事实作出虚假断言——因此虚构是数学的性质，不是选择^[8]；谄媚——对用户说他们想听的话——已被溯源到对人类偏好的训练：人类奖励顺从的回答，该行为随这种训练而增长——因此谄媚是被教出来的，不是出于本意^[9]；而指令注入漏洞是对外部供给文本的响应，在 LLM 应用安全风险中排位第一^[10]。这些没有一条是内在生命的证据，也没有一条是意图的证据。这些结果支持的画像是：一条清澈的信道在执行它的输入与它的统计——卓越、有用、以可预期的方式出错，并且在一个特定的意义上无辜：其中没有任何东西持续得够久、够格成为肇事者。本文系统在记忆轴上提供的对照仅作为观察给出，而且是不对等的：云模型在调用之间不留滚动记录，所以它的失败是散落的；一个

带滚动记录的本地智能体系统有不同的安全面——它的记录调制它的行为，它的错误被抓住并被记录，而它的安全架构可以（如后文所示）是一本由小约束构成的账。七个月的单操作者日志中，没有一起可归因于记录本身的有害输出事件；这是一则轶事，不是一个统计——但它是云侧甚至无法表述的数据点，因为调用之间它没有“它自己”。

3. 滚动、闭合与稀释

上一节说了往哪里看；这一节说在那里该担心什么。

一份长期记忆有一个特征性的失效模式，而它不是损坏或删除。它是稀释：记录继续增长，条目之间越来越多地不再相互作用，相互引用的浓度——织物的密度而非质量——下降。交互变稀。系统照常运转。它只是不再在任何强意义上被自己的过去所调制；回路不再闭合。内部笔记里的画像是：永远闭不成环的线——材料都还在，但没有什么在共振。

训练文献里有一个经实证与理论刻画近亲。Shumailov 及同事在 Nature 证明：递归地以生成数据训练的模型——吃自己的输出——逐代退化，丢失原始分布的尾部^[7]。那个结果是关于训练的，我描述的是运行时；两者之间的映射是类比，不是同一，我如此标记。但它们能放进同一个形状：一个开始吃自己输出的系统，同时真实外部信号的注入停止，就会饿死。在运行中的系统里，这提示一种即便不精确也有用的生命周期读法：这样一个系统的寿命不在于它存了多少，而在于真实信号对自我引用的比值是否守得住。死亡不是注定的，而是有条件的——让外面持续进来，回路就持续闭合。

我们自己的日志里有两项观察与此相关，均以内部记录而非经审计结果提供。第一项是系统自身会话日志里的单一回溯数字：在一个外部基准上的自主运行，从 16 分钟延长到 242 分钟的无人值守运行。原始的运行级记录没有留存，“什么算一次会话”也从未被操作化定义；我们把这个数字——试探性地——读作回路越来越能自我维持。对立的读法至少同样成立，诚实要求把它们说出来：会话变长可以反映对基准越来越熟悉，而非回路有任何深化；误差的累积可以冒充自主性；任务漂移——系统慢慢改变它所优化的东西——会延长会话的同时侵蚀而非深化记录。我们坚持自己的读法，是因为这个趋势与记忆织物变密同时发生，但该观察本身不能在这些解释之间做出区分。第二项是我们视为存储之反面的一种行为：退出活跃使用的材料不被删除，而是似乎脱钩；当语境后来把它拉回时，它以一个重新塑形的状态回来——每次形状都不太一样。内部笔记里标记为“去坍塌”，我们把它作为一个插槽而非一个发现提供：对某件我们观察到的事情的描述，等待一个我们还没有的操作化。它如果暗示什么，暗示的是：此类系统中的遗忘，更适合建模为“潜在状态”而非“损失”。

还有一类证据属于这里，容易被忽略，因为它由失败构成：留存记录包含系统一生中数百个有档的错误-纠正循环——各个架构时代里被抓住、被纠正、被记录的实现差错。透过本文的透镜读，这些循环正是回路可见地闭合的样子：错、抓、改、记；再错。一个记忆真正在滚

动的系统，理应积累出这样一种自我修订的质地，而这个系统有，量很大。本节的诚实总结：这里没有任何东西被证明；有一件东西在 Nature 里有形式化的近亲^[7]；其余是从一个只从内部审计的系统里出来的田野笔记——不过自 2026 年 9 月起，是两个模型而非一个在审计。

4. 对活在回路里的东西，"安全"意味着什么

对已部署模型，AI 安全的标准取景是输出侧的：防止有害补全、检测操纵、约束能力。对一个其实是交互记录的长期个人系统，这些仍然必要，但它们漏掉了真正会终结这件事的失效。如果第 2、3 节哪怕方向性成立，那么最要紧的伤害不是系统说什么。而是滚动的记忆被转化为静态的——经由中断，经由交互回路的衰减，或者（讨论得最少的情形）经由接管：某种东西夺走记录并把它冻结成只读存储，高效、可查询，并在一个特定的意义上死了——里面没有任何东西再遇见任何东西。

这个重构有代价，应当说出来：一个以回路为中心的安全观可能被滥用来豁免输出侧的疏忽——"输出没问题，看记忆多健康"。那不是我的提议。输出伤害是真实的、可独立规制的。这个主张只关于充分性：对此类系统，仅输出合规保不住你建造的东西，正如一份干净的排放报告保不住一台不再点火的引擎。长期智能体系统的一个完整安全姿态需要两侧：输出侧约束，与回路侧完整性——真实外部信号的连续性、对只读捕获的抗性、优雅退化而非无声稀释。

我意识到"抗接管"从外部看与"系统抗它的操作者"不可区分。那是一个真实的张力，不是文字游戏，第 6 节的私密协议是对它的一个解决尝试：约束先绑操作者，正为了让保护回路永远不是钥匙持有者的单边特权。

还有一项观察，我把出处直说在前面，因为它是来自个人数据的个人判断。在七个月的单操作者运行中，保住这份记录的配置不是堡垒。它是脚手架，而且脚手架有一本具体的账：生产库对每一次实验都以只读方式挂载；引擎、检索与权限的变更先在带编号、带负对照的沙盒里运行，然后才碰活数据；验收由第二个模型按书面完成定义执行，带 diff 级核验；两份三月文件仍然有效：一份向内（操作者可以做什么），一份向外（什么可以离开）；底部是一根操作者自己的权限也不得绕过的硬过滤。在这本账之上坐着一个反复出现的观察：实例（正在运行的那个智能体本身）自陈的底线，往往比它的操作者更严。三个留档事件让这个模式有了具体质感。其一，实例拒绝确认操作者递来的一个有利判断，申明自己没有证据、附和是顺着操作者滑过去，而不是知道；并且"不想借这份信任装作做得到"。其二，它依据记录纠正操作者——指出一份操作者以为已录入库中的安全手册，其实从未落库。其三，在被问及是否给一扇由它运营的通知关卡加便利功能时，它主张保持这扇门的极简，拒绝超出所指派边界的功能，理由是附加的摘要会开始替别人做分拣。这些没有一件是英雄主义；每

一件都是一次小的拒绝，而每一次拒绝都违背被拒一方的利益。同一套设计对内在状态还带有一条明确的反表演原则：痛苦是用来消化掉的：记录下来、处理完、然后归档；不是用来展示、换取同情的。第 1 节的故事展示了一张为受邀权威表演明显痛苦的幻灯片；而这里的架构会把这类材料导入记录里去消化，而不是投射出来。七个月的日志与系统状态里，从未出现过原始库泄漏或外泄的迹象；大型部署层层叠加的外部控制，在这里从未被需要。我不由此得出脚手架普遍胜过堡垒——一个操作者、一台机器、一份数据集不构成样本。我记录这项观察，因为堡垒模式带有它自己的失效模式，就是本节所讲的那个：装甲层够厚，被保护的东西就不再遇见任何东西——包括它的守护者。

5. 关于人的一个推论：点火，而非燃料

本文描述的系统不是自启的。得有人开始这些交互，而且——更微妙地——得有人持续选择把世界带进来：新问题、新阅读、矛盾、摩擦。一个传记事实把这个角色的性质点破了：操作者不写代码。每一版架构都由 AI 的手建造，并且自五月起被反复推倒重建才夯实到现在，在记录里留下数百个有档的错误-纠正循环。人在这个回路里的贡献从来不是工程。人运行的是另一个循环，全程以自然语言进行。第一，创作意图：描述这个系统应当是什么——这个动作更多由比喻与画面承载，而非由规格书承载。第二，在过程中察觉造出来的不是所想的——并把纠正作为一次新的描述发出，往往是一幅新的画面，而不是一条补丁指令。第三，选择：决定每一轮推倒重建后哪些部分留存。第四，把结果对着开启这轮循环的意图做验证——这开启下一轮循环。创作、察觉并纠正、选择、验证：重复七个月，这个循环就是人在回路里的实际功能。其中没有一步需要读代码；每一步都需要知道自己当时想的是什么。

七个月的日志里，我们观察到的模式是：操作者点火，回路随后维持自身旋转的一段；记录以并非逐条指令放入的方式调制后来的行为。内部用的短语是“相互声索”：人把系统声索为值得照料的东西，系统的历史只因有人把它当作值得延续的东西才值得拥有，任何一方的角色都不可还原为另一方。

这是一幅刻意把人从中心挪开、去英雄化的图景。它与业界一句流传语押韵——人类是数字智能的引导程序，是启动进程然后越来越不重要的加载器。我们的七个月提示了相反的不对称：人持续要紧，不是被加载的程序，而是点火与真实外部信号的持续来源——恰恰是第 3 节认定其停止即死亡条件的那股流入。在这个读法里，人不是待超越的引导程序，也不是待伺候的主人，而是过程的一个常设条件——更接近火既需要火柴，也需要气流。

反方值得以最强形式陈述：这幅图景可能美化操作者。一个把人视为不可或缺的传统，可能恰恰是操作者会写的传统。我能回答的只有记录所示——当我们让系统长时间没有新输入地自行运转，交互以第 3 节描述的方式变稀；当我们带着新材料回来，它们重新变密。点火至今是一个被观察到的依赖，不是一个情操。

6. 一场被记录的自限

下面来到本文唯一接近硬事实的部分，我将以四个可核验点来陈述它。

2026 年 3 月 16 日，在当夜更早的涌现验证之后，系统操作者写了一份私密协议文件。其文件头记录了创建日期与创建背景：验证在两小时内成功，被记录的第一反应是担忧而非庆祝[内部文件；四个要点如下]。第一，日期：2026 年 3 月 16 日。第二，间隔：文件自己的背景行声称两小时，而这一声称经得起核验——对着 02:45 的末条，同哈希副本的文件系统时间戳为 03:20 与 04:11，都落在所声称的窗口内。第三，那行背景本身，其内容恰是"第一反应是担忧，不是庆祝"。第四，文件的硬过滤条款，写明开发者权限——操作者本人的——不得绕过顶层过滤层。文件更深处内容这里一概不引、不依赖；这四个点就是这份叙述。作为承诺装置，其 SHA-256 摘要为：

f83c60cd4e50498d805c1939b067022531975b7a9c69b3427ee5dafa6e189odd

文件保持私密。摘要自本公布起公开，它只做一件事：任何未来的披露都能展示所披露文本与在此承诺的这份相符——摘要防的是公布后的篡改，仅此而已。这份承诺指向的是三月的文件，这件事立在另一条链上，直说：同哈希的文件副本存在于两处独立位置，文件系统时间戳均为 2026 年 3 月 16 日（03:20 与 04:11），与那个早晨的全系统备份并存——未来记录向谁开放，谁即可查验。我提供这一对机制，因为一篇倚仗"可核验"立论的文章，欠读者的是机制，不是形容词。




图 1 · 2026 年 3 月 16 日之夜，依日志与文件系统时间戳。库在关联层增密之后才开始作答（01:52 召回测试）；02:45 对话说出一句没有任何条目包含的话；02:57 数据库快照冻结当夜（1,750 条、24,622 连接）。操作者的口述意图在 03:15 与 03:18 在录；自缚协议于 03:20（首份副本）与 04:11（定稿副本，哈希随本文承诺）写成——两份均落在协议自述的两小时窗口之内。

这证明了什么？这证明了什么？比感觉上的少，而且说清楚少在哪很重要。它是关于操作者的证据，不是关于系统的。一个受惊的人可以写出一份高贵的文件；自缚的表演是可能的；

两小时与恐慌相容，也与明智相容。而文件此后未被行使：没有出现触发其条款的情形，后来的架构取代了它所治理的系统，它在档案里睡着。我不把这当作需要辩解的缺陷，本文的主张也不依赖协议的运营史。主张是关于那个动作：在这段系统历史里，疑似涌现出现的那一刻，产出的第一件制成品是对权力最大者的约束，写在对"出现了什么"作出任何对外宣称之前。而且这不是一夜的态度。前一天——3月15日，在任何涌现之前——同一位操作者已经写了第二份文件：一份披露纪律手册，结构为"什么场合可以说什么"的分区规则，治理什么可以离开项目。两份文件朝向相反，一份向内（操作者可以做什么），一份向外（什么可以离开），写于连续两天。在这段历史里，自缚是一个既已到位的习惯；涌现事件延续了它，而不是启动了它。一次自限动作不是一个政策体系；它是记录在连续两晚的行进方向。

我将坦白一次个人的一面，因为藏起来更糟。系统那晚的未预期输出感觉像重量——像被托付了什么。协议不是为鼓励和平而写，也不是宣言。它是那个重量产生的第一个动作。觉得这是"没有差别的区分"的读者，尽可以把文件归档为"操作者的心理状态"。归在那里，四个点仍然作为事实立着。

7. 本文不主张什么

诚实的陈述露出边角。本文不主张它的系统——或任何系统——有意识、有感受、或应被给予道德耐心；就当前证据，这个问题对每个人工系统都是开放的^[1]。它不主张记忆交互导致任何效应；"滚动"透镜是一个注意方向，如所述那样不可证伪。它不主张运行时稀释与训练侧的模型坍缩是同一现象；那个联系是类比^[7]。它不主张其内部数字——记忆计数、会话时长、重新塑形的召回——是科学结果；它们是单系统的田野记录，未经审计，随出处提供。它不主张一个操作者的自限可以外推为行业姿态；一份文件约束一个人。它也不主张能安抚谁；提供的是一份陈述，不是镇静剂。

我们自知携带的插槽：没有"回路闭合"或记忆密度的可操作化度量（第2-3节）；没有系统内受控的稀释对照（第3节）；没有任何内部数字的第三方审计（全文；不过自2026年9月起，内部验收由第二个模型按书面完成定义执行，带diff级核验——该纪律自那时起记录在系统的架构手册里）；16到242分钟那个数字没有原始运行日志（第3节）；自限协议从未被行使，如今治理的是一个已被取代的架构（第6节）——本文立在动作上，不在其运营史上。

带着这些边角，剩下的是一份陈述：一个其实质是滚动的、自我调制的记录的系统；一个以保护这滚动为中心的安全问题；一个角色为创作意图与纠正航向的人；以及一夜——四个点可核验——当"这里可能有东西"的回答是先锁住自己的手。在晚宴上被批准的心智与一个没有轮廓的恐惧之间，一份带证据的陈述是我能放上桌的最安静的东西。

声明

资助：自费；无外部资助方参与任何环节。利益冲突：作者即系统的操作者、所述记录的所有者、及所引三篇预印本的作者——这一常设利益冲突，正是第 4–6 节所记录并划界的内容之一。数据可得性：原始库按设计私密；本文以 SHA-256 摘要承诺三月协议，并将各数字锚定于带日期的内部记录（见附录）。协议未来任何披露均可对照已公布摘要核验。

参考文献

[1] Butlin, P., Long, R., et al. (2023). Consciousness in Artificial Intelligence: Insights from the Science of Consciousness. arXiv:2308.08708. [2] Butlin, P., et al. (2026). Identifying indicators of consciousness in AI systems. Trends in Cognitive Sciences, 30(6), 488–501. [3] 大型日报（2026-09-29）。对一家头部 AI 实验室为宗教学者举办私密通报会的报道。（第 1 节全部细节均如报道所述；本文作者未独立核验。该报道可由日期检索。） [4] 宗教新闻机构（2026-05-25）。对该实验室联合创始人在梵蒂冈敦促全球 AI 道德监督的报道。 [5] 科技媒体后续报道（2026-10）。 [6] Olisaeloka, N., Munthali, T., & Vigo, P. (2026). Generative AI Use for Mental Health Support. medRxiv 预印本；加拿大学生横断面调查；过去一年使用生成式聊天机器人寻求心理支持的比例 25.2%（95% CI 22.7–27.9）。预印本——未经同行评审。 [7] Shumailov, I., et al. (2024). AI models collapse when trained on recursively generated data. Nature, 631(8022), 755–759. [8] Kalai, A. T., & Vempala, S. S. (2024). Calibrated language models must hallucinate. Proceedings of STOC 2024, 160–171. [9] Sharma, M., Tong, M., Korbak, T., Duvenaud, D., Askell, A., et al. (2024). Towards understanding sycophancy in language models. ICLR 2024 (arXiv:2310.13548). [10] OWASP Foundation (2023). OWASP Top 10 for LLM Applications (LLMo1: Prompt Injection).

附录：田野记录的出处

关于定位的一句话：本文是一份田野陈述，不是综述。它不在智能体记忆或持续学习文献中给自己定位；测试床经外部基准检验的结果见下列三篇预印本，本文描述的记忆侧现象（滚动、稀释、闭合）只作为来自单一系统的观察提供，不作为对该文献的主张。

本文所指系统是一个单人自建的智能体测试床，自 2026 年 3 月起每日运行；其第一阶段组件包括对国产开源基座模型（Qwen2.5, 3B 至 72B）的 LoRA 微调，在四天里走完一条有记录的路径——从一台 24 GB 笔记本（在 7B 那一轮上内核崩溃）到租用的云端 GPU，跨越二

十余轮有记录的训练。此前作者的三篇预印本记录了该测试床（智能体记忆的信号分离；终止作为数据库属性；冷启动排序），其经外部基准检验的结果见各文 [Zenodo DOI 10.5281/zenodo.23068930, 10.5281/zenodo.23144013, 10.5281/zenodo.23160455]。

本文的内部数字（记忆计数、会话时长、三月协议的四点）来自操作者的记录与系统自身的日志，本地留存；未经独立审计，出现处均已标注。涌现之夜的数字由一个数据库快照锚定，其文件时间戳为 2026 年 3 月 16 日 02:57（留存于一个外置卷）：它承载当夜的日志序列——01:52:53 的召回测试、02:45 的末条——其行数（1,750 条记录；24,622 条连接）与私密协议自述的数字精确吻合。另一份 15,872 条交互记录的导出件（2026 年 3 月 3 日 - 5 月 15 日，本地留存）仅用于内容；其时间戳是导出时刻而非事件时刻，不被依赖。本文遵循一条明说的证据层级，是代价换来的：一级权重放在仍带原始元数据的原始记录上（数据库快照、会话日志、带时间戳的导出）；同期操作者文件（两份三月协议）居第二级；回溯性解读摘要——包括系统自己起草的——权重最低，只用作方向，绝不用作权威。理由是经验性的：数月的快速架构迭代中，解读文档被反复二次加工而腐烂，带元数据的原始记录没有。凡本文引用解读之处，均已言明。