

记忆的浓度、排序与代谢：长期运行智能体记忆系统中三个被混用的信号

赵宝峰

独立研究者

Salience, Ranking, and Metabolism: Three Conflated Signals in Long-Running Agent Memory Systems

摘要

长期运行的智能体记忆系统普遍把"重要性"当成单一信号。我们论证它其实是三个被混用的信号，而这一混用是结构性的设计错误，而非实现细节。一条 2023 年为模拟表演写的打分公式（relevance、recency 与 importance 的加权求和），未经检验地进入了生产系统，让"重要性"的三个职责（沉淀、排序、退役，下文分离为浓度、排序、代谢）在同一个信号里相互干扰。本文的出发点是一条服务链：记忆为 LLM 服务，LLM 为人服务。抽掉中间环节、让记忆直接服务人的查询，我们认为再复杂的系统也会向 RAG 漂移。基于一个自 2026-03 起连续运行约 7 个月、约 38,000 条记忆条目、148,000 条关联边（2026-08 审计快照，现库约 108,000 条）的真实系统运维数据，论证"重要性"至少是三个（我们认为）最好分开的正交信号：浓度（数据的固有属性）、排序（查询时刻的算法服务）、代谢（条目的生命周期退役）。我们记录三类混用的生产故障：计数器内部的 93 倍语义偏斜、一个结构盲视的质量度量（报 0.999，而同库结构感知一致性读 0.101）、以及 88% 的原始记忆为"孤岛"（写作时 73%，不加清理仍在下降）却含结构上最核心的根。检索侧的压力可测：访问分布基尼系数 0.960，Top 1% 节点吸走 51.9% 的全部访问。我们提交一套带四条不变量（I0 - I3）的信号分类学、七条设计法则，以及两个当天可执行的自查工具（行为静默检验、RAG 判别）。本文不宣称 benchmark 优势；证据全部来自作者自己的失败；这一点上，我们数据充足。

关键词：智能体记忆；信号分离；正反馈偏差；RAG；记忆治理；立场论文

Abstract (EN). Long-running agent memory systems commonly treat "importance" as a single quantity. We argue that it conflates three distinct signals, and that the conflation is a structural design error rather than an implementation detail. A scoring formula written in 2023 for a simulation demo (relevance plus recency plus importance) moved into production systems unexamined, letting the three jobs of "importance" (sedimentation, ranking, retirement, later separated here as salience, ranking, and metabolism) interfere with one another within a single signal. Our position rests on a service chain: memory serves the LLM; the LLM serves the human. And memory must be *memory*: self-describing and self-metabolizing, its salience and retirement decided by data and lifecycle rather than one-shot human-delegated verdicts (Invariant I0). Skip the middle link and even the most elaborate memory system drifts toward RAG. Since March 2026, over about seven

months of production telemetry on a single conversational system (~38K raw memory items, ~148K association links as of the 2026-08 audit, the live store now holding ~108K), we argue that "importance" is at least three orthogonal signals that are best kept physically separated: salience (intrinsic to the data), ranking (a query-time service), and metabolism (lifecycle retirement). We document three production failures of conflation: a $93\times$ semantic skew inside one counter, a structure-blind quality metric reporting 0.999 while the store's structure-aware coherence read 0.101, and 88% of raw memories being "islands" (73% at the time of writing, still declining without cleanup), yet containing the most structurally central roots. The retrieval-side pressure is measurable: an access-distribution Gini coefficient of 0.960, with the top 1% of nodes absorbing 51.9% of all accesses. We contribute a signal taxonomy with four invariants (I0 – I3), seven design laws, and two same-day audit tools (the Silence Test and the RAG Test). No benchmark supremacy is claimed; all evidence comes from our own failures, of which we have plenty.

1. 引言：记忆为谁服务——RAG 的遗产问题

「思维能在下次生效吗？——可是你上次整理了什么，你自己都忘了。」

——本系统语料原话（轻度改写脱敏）

先回答一个比打分公式更根本的问题：记忆为谁服务？

人的记忆不为查询而建。一件事沉下去，多年后自发浮现，以气味、口吻与处理惯性。人遗忘的方式是活着：不是执行删除策略，而是被后来的生活慢慢覆盖。人的记忆没有索引，也从不给自己的回忆打分。

LLM 相反：默认状态下每一次对话都从零开始。它的记忆无法自然生长，只能被建设。

我们给出的立场是一条服务链：记忆为 LLM 服务，LLM 为人服务。一旦抽掉中间一环（让记忆直接服务于人的查询），那么无论系统包装得多复杂（抽取、合并、图谱、分层），我们主张它本质上仍只是一个 RAG [10]：一个人查、一台搜、把结果塞进上下文让模型当粘合剂。RAG 作为工具无可指摘；作为记忆架构，它是类别错误：它让记忆的全部生命都发生在检索时刻、由查询塑造，记忆成了索引，模型成了管道。

人脑记忆与硅基记忆是两种介质；介质之间需要桥梁，而不是直接接线。把人的文档直接拼接进上下文是接线；把原话沉淀为结构、让派生围绕锚点收敛、让因果链可溯、以模型能生长的方式重建过去，这才是桥梁。我们对人为干预的态度同此：记忆的结构应当被认出来，而不是被造出来。桥梁要立得住，至少需要三种不同的材料，即本文的三位主角。

服务链回答了记忆为谁服务；还有第二个同样根本的问题：记忆凭什么成立？我们的副论点是：让 LLM 拥有记忆，前提是让记忆本身就是记忆，而非被人为干涉的记忆。浓度不是谁打出来的分数，是数据自己的形状；代谢

不是谁执行的删除策略，是记忆在自己生命周期里的生老病死。数据库的语义是二值的：一条记录或者在，或者不在，动词只有增删改查；记忆的语义是活的（生长、收敛、退役、循环），全部由数据内生决定：数据决定浓度，数据决定代谢。写入时请 LLM 打一个 1 – 10 分，或请 LLM 裁判裁决删留，都是在数据与它自身的重量之间插入一个外来判决，这是人工干涉的记号。并行工作 [7] 问"智能体记忆是不是数据库"；本文的回答是：不是，并且给出它是什么的正面纲领：一个自洽的、有代谢的记忆生命体。

行业当前的默认做法仍停留在检索时代：把记忆当成一件为查询而优化的东西。RAG 心智的具体化石，就是那条从 demo 继承的公式。2023 年，一个由 25 个 LLM 智能体组成的小镇模拟（Generative Agents [1]）提出了如今几乎是行业默认的记忆检索公式：

$$\text{score} = \text{relevance (余弦相似度)} + \text{recency (指数衰减, 因子 0.995, 按最近访问计)} + \text{importance (写入时 LLM 打 1 - 10 分)}$$

这个公式为一场模拟表演而写，却成了大量生产系统的骨架。问题不在求和（加权融合本身无辜），而在于它悄悄让同一个信号同时打三份工：决定一条记忆有多厚（它是不是被大量后续内容围绕的锚点）、决定这次召回它排第几（此刻合不合适）、并间接决定它还能活多久（清理逻辑普遍引用计数/热度类输入）。把三个信号塞进一个字段，就像把心率、车速和油耗刻进同一块表：指针在动，但已无法说明自己在报哪一项。

本文论点：这不是实现细节的粗糙，是结构性的类别错误。贡献四项，每项均可独立检验：

- C1（论点） 记忆服务链的重新定位：记忆为 LLM 服务、LLM 为人服务；记忆直接服务人的查询即趋向坍塌为 RAG；
- C2（分类学） 浓度/排序/代谢三信号的形式化区分、记忆自洽原则与四条不变量（I0 – I3）；
- C3（证据） 三条生产故障记录（93 倍字段异义、0.999 假健康、88% 孤岛根节点）与分离后的现场读数（93→2.2 倍）；
- C4（工具） 两个当天可执行的自查工具：行为静默检验、RAG 判别。

全文论证路线：§ 2 相关工作定位病灶 → § 3 方法给出诊断框架 → § 4 案例研究提交病历 → § 5 – § 6 给出应用推论与自查工具 → § 7 – § 8 划定边界并收束。最后，防三处误读。本文不反对检索；检索是记忆合法的取用动作，我们反对的只是让它兼任唯一的裁判；本文不反对打分；分数可以作为排序层的输入，不能充当浓度的代理，也不能充当代谢的终止判据；本文不提交新架构；交付的是体检框架与不变量，任何现有系统都可以在不推倒重来的前提下自检与修复。

2. 相关工作：三种继承者与一股批评浪潮

(a) 教科书形态——检索即强化。Generative Agents [1] 的新近度按最近访问衰减：被检索的记忆获得新近度刷新，从而更容易被再次检索。这是推荐系统领域被充分研究过的正反馈/流行度偏差 [5]，在推荐系统里它的终点叫信息茧房；搬进记忆系统，终点是记忆茧房：一个只剩自己爱 recall 之事物的模型。据我们检索所及，这一批评在智能体记忆语境中尚未被正式提出。

(b) 融合形态——一个裁判管三件事。Mem0 [2] 每次写入做两遍 LLM 调用：抽取候选事实，再由 LLM 裁判对向量相似邻居做出 ADD / UPDATE / DELETE 裁决。浓度判断（新事实多重要）、代谢决策（旧事实该不该死）、留存材料（留什么给检索）融合在同一次裁决里，且由"相似性能检索到谁"这个偶然因素触发。公允地说，业界已开始正视这一痛感：Mem0 团队已在讨论淘汰与遗忘 [3]，社区在提议按访问频率做生命周期清理 [4]。在这类工作开始把检索衰减与淘汰分开处理之处，本文的独特贡献是将其一般化为带不变量 (I0 – I3) 的三信号分类学，并为每一种故障模式提供纵向生产证据；问题已被承认，但药方尚未形成。

(c) 半分离形态——最接近，差一步。Zep [6] 的双时态边让被取代的事实失效而非删除（历史保全），是对代谢最清醒的处理；但其检索排序仍是 relevance + recency + episode usage；使用频率直接进排序，行为对度量的污染仍在。MemGPT [12] 普及了分层记忆管理（工作上下文与外存之间的分页），但其淘汰同样读取新近度与使用量。

(d) 正在形成的批评浪潮。并行工作 "Is Agent Memory a Database?" [7] 已批评现有打分是"检索时刻的局部启发式"。我们同意诊断，并向前两步：给出完整的三信号分类学与不变量，以及生产级纵向故障证据。一股批评的浪潮正在形成；本文为它提供一个框架。

(e) 一个预设的反驳：为什么不干脆请 LLM 打分？最自然的辩护是：让 LLM 在写入时给重要性打分 ([1] 的 1 – 10 分)，或在更新时当裁判 ([2])，不就有"重要性"了吗？三个理由都不行。其一，这是 I0 违例：一次性外部判决代替了数据自身的重量，而判决者看不到未来，写入那天无人知道哪条原话三个月后会成为关键判断的唯一根据 (§ 4.3)。其二，裁判是检索的囚徒：LLM 裁判只能看见向量相似性能送到它面前的邻居，于是"什么算重要"被"什么相似"绑架 (§ 2b)。其三，判决不可代谢：分数一旦写下便成为永久标签——实质上是一次性的在/不在判决。

表 2：三种继承者 × 三信号的处置矩阵

系统	浓度（固有属性）	排序（查询服务）	代谢（生命周期）
Generative Agents [1]	无独立信号（写入时 LLM 打 1 – 10 分，一次定终身）	relevance + recency（访问刷新）+ importance 混合	无代谢机制
Mem0 [2]	与代谢、留存融合于同一次 LLM 裁决	向量相似 + 裁决结果	同一裁决内 DELETE（由相似邻居触发）
Zep [6]	无独立信号	relevance + recency + usage（行为入序）	双时态失效而非删除（最接近 I2）

系统	浓度（固有属性）	排序（查询服务）	代谢（生命周期）
本文	数据固有属性，作用域内测收敛，不受行为影响	有界 [0,100] + 衰减，绝不写回数据	条目级级联，生命周期触发，不看热度

3. 方法：三信号定义、不变量与正反馈分析

记号：以 $\sigma(x)$ 记条目 x 的浓度， $\rho(x)$ 记 x 的排序层分数， $\mu(x)$ 记 x 的代谢状态；三者的定义域与写入者互不相同，这正是本节的全部主张。关于 ρ ：存储的分数只是每次查询排序的输入，查询时与查询相似度融合；持久分数本身不携带查询。

定义 1（浓度 / Salience）：条目 x 的结构属性（以库内相对方式度量）——“多少派生内容以 x 为锚点收敛”，且必须在正确的作用域内测量（跨语义域计数得到的是扇出噪音，不是收敛）。关键性质：不被召回行为影响。它是数据的形状，不是数据的热度；无人检索时，它依然生长。具体实现中，我们把浓度度量为归一化收敛密度： $\sigma(x) = \log_{1p}(\text{锚定入边的物理量}) / \log_{1p}(p_{99})$ ，且只统计锚定类边型（raw_basis、ai_basis、derived_from）；召回驱动的边按构造被排除，故 σ 在任何召回行为下保持不动。

定义 2（排序 / Ranking）：查询时刻的算法服务输出；有界计数（如 [0,100]）叠加遗忘曲线式衰减是合法实现。关键性质：可随时整体重算、只服务消费方、绝不写回数据。我们的实现：艾宾浩斯式分数 $\rho = \text{count_norm} \times \exp(-\Delta t / S)$ ， $S = 7 \times (1 + \text{count})$ ，并硬性封顶 $\text{count} \leq 100$ 。其中 count 为召回计数（封顶 100）， count_norm 为该计数按封顶归一到 [0,1]， Δt 为距上次召回的天数， $S = 7 \times (1 + \text{count})$ 与 Δt 同为天单位（艾宾浩斯遗忘曲线用于 LLM 记忆的做法承自 MemoryBank [11]）。

定义 3（代谢 / Metabolism）：生命周期决策，以条目为单位级联（原话退役，其派生物与关联边一并退役）。关键性质：触发条件是生命周期事件，不是任何热度或排序分数。低频 $\neq$ 过期——低频是根节点的天性，不是它的罪。我们的实现：退役是一次软状态标记，以条目为单位级联；它只读生命周期事件，绝不读任何计数器。图 1 概括了三个域与隔开它们的墙。

三分离在这里还有一条更深的注脚。排序的新近度衰减把时间当作测量单位，这没有错，钟表是排序层的合法工具；但浓度不是时钟的函数，它是互动的沉积，由多少派生围绕收敛构成，与墙上时钟无关。把时间还给钟表，把互动还给记忆：这正是排序与浓度在物理上必须分家的那道缝。

不变量：

- I0（不代言）：记忆的持久属性（浓度、存活）不得由写入时刻的一次性外部判决（如 LLM 打分、LLM 裁判裁决）赋值；它们是数据与生命周期的内生属性；
- I1（不污染）：排序信号的任何变化不得改变浓度与数据本身；

- I2（不误杀）：代谢不得以排序/热度分数为唯一触发条件；
- I3（不同义）：同一物理字段不得承载多种语义。

正反馈草图（图 3）（为什么混用必然恶化）：设排序分 s 依赖新近度 r ， r 随时间衰减但随访问刷新，则 $\partial s/\partial \text{access} > 0$ ，而 access 概率又随 s 上升——自增强回路。只有把"访问"严格关进排序层、并禁止它写回任何持久字段（I1），回路才被物理切断。这不是工程洁癖，是切断反馈回路的最低结构要求。这股压力的大小是可实测的：本系统当前（三分离之后、有界封顶的）排序层访问分布：25,705 个节点，访问计数基尼系数 0.960（图 7），Top 1% 节点吸走 51.9% 的全部访问，Top 10% 占 96.9%，85.8% 的节点零访问。这组数字的正确解读是：排序层的赢家通吃本身合法；它被关在服务层内、随时可整体重算；数字的全部意义在于警示——这样一股分布，若被写进任何持久字段，就是对 85.8% 零访问节点的淘汰判决，其中多数是根。




图 3 | 正反馈回路与切断方式。

左：混用形态下，检索刷新新近度（Generative Agents 的 0.995 衰减按最近访问计）， $\partial s/\partial \text{access} > 0$ 构成自增强回路，无稳态与再平衡机制时终局为赢家通吃。右：I1 将访问敏感性关进服务层并禁止写回持久字段，回路被物理切断；对照人脑：测试效应的强化有突触稳态与睡眠巩固再平衡配平——"要学就学全"。

访问量累计占比



这样一股分布若被写进持久字段 = 对 85.8% 零访问节点的淘汰判决
(多数是根) ——此即 I1 存在的理由

图 7 | 排序层访问分布的洛伦兹曲线 (生产库实测, 2026-08)。

25,705 个节点的访问计数分布：基尼系数 0.960，Top 1% 节点占全部访问的 51.9%，Top 10% 占 96.9%，85.8% 的节点零访问。注意：该分布测于三信号分离之后——排序层的赢家通吃是合法的（有界、可重算、不写回）；本图的意义是量化正反馈回路的压力大小，并说明为何任何持久字段都不得引用此类分布（不变量 I1）。

一条记忆的一生（推演，图 2）。把三个定义放进同一条时间线，差别立刻具体。第 0 天，一句原话入库：接线式世界里它被 LLM 打了 5 分，从此带着终身标签生活；桥梁式世界里它没有分数，只有身份——原话锚点。第 30 天，它碰巧被召回两次：接线式里新近度被刷新、排序分上涨，开始吸引更多召回；桥梁式里排序分同样上涨，但这一切被关在服务层，它的浓度纹丝不动，依旧零派生围绕。第 90 天，无人再问起：接线式里它的分数随衰减归零，进入清理候选；桥梁式里它同样“凉了”，但凉的只是排序，不是生存资格。第 120 天，一条新判断需要根据，发现唯一锚点是它：接线式世界在第 100 天已按热度把它删了，判断失去根据、仪表盘全绿；桥梁式世界里它被派生围绕，浓度第一次真正生长，从孤岛成为根。同一条记忆，两种命运；差别不在任何一步的算法优劣，在于三件事是否分家。

与人类记忆的对照（与一条诚实的边界）。人脑的检索确实会强化记忆；测试效应是认知心理学的经典结果 [8]；那么 I1“禁止访问写回数据”是否反生物？不是，是生物学被引了一半：人脑的强化发生在独立的突触基质中，受稳态再平衡约束，并在睡眠巩固里被整体重新配平 [9]：强化有界、有回账、有再平衡。软件计数器只有强化、没有稳态：无界的正反馈正是 § 2a 的记忆茧房。I1 的准确读法因此不是“不许学生物”，而是“要学就学全”：访问敏感性可以存在于排序层（有界、衰减、可重算），持久层必须保持行为无关，除非引入带稳态与再平衡的独立机制。




图 1 | 三信号架构：数据域、服务域、生命周期域三域分立。

浓度 σ 居数据域（结构固有，行为无关）；排序 ρ 居服务域（有界+衰减，可重算，禁止写回，I1 墙）；代谢 μ 居生命周期域（条目级联，热度禁入，I2 墙）；I3 禁止字段混语义；I0 禁止外部判决代言持久属性。虚线红叉为被 I1 切断的“访问写回”正反馈路径。

4. 案例研究：单一生产系统的故障记录（n=1）

系统背景：自 2026-03 起连续运行约 7 个月的对话式智能体记忆系统，双库结构（原话层 + 蒸馏层），约 38,000 条记忆条目、148,000 条关联边（2026-08 审计快照；现库约 108,000 条）。以下数字均来自生产库真实回放。

表 1：证据时间线（单一库）。

时点	发生了什么	队列
早期审计（修复前）	全库审计发现 93 倍字段语义偏斜与 88% 孤岛占比	审计时的整层原话
修复后（字段拆分、封顶 [0,100]）	类型间差距 93 倍 $\rightarrow$ 2.2 倍；峰值钉死 100	同字段重测
2026-08（修复后快照）	孤岛占比 67.8%（用户，n=5,956） / 82.6%（AI，n=3,173）；合计 73.0%（n=9,129）；基尼 0.960（n=25,705）	当月原话
2026-10（现库）	关联边约 108,000；原话层约 13,364（用户 6,289 + AI 7,075）	当前

术语表（本文用法）：皮层（cortex）——蒸馏节点库（约 3.8 万节点）；原话层——逐字话语；蒸馏层——派生节点；锚点——派生内容收敛于其上的节点；驻波池——带已完成向量且权重超过活跃门的活皮层节点；活跃门

——允许节点进入该池的权重阈值。

本节读法：这些是来自单一系统的"识别与处置记录"，不是受控试验。把被三种语义共用的字段拆开，跨类型差距必然收缩（93 倍→2.2 倍部分是拆分的定义性后果）；峰值停在 100 也是因为封顶即 100。孤岛占比变化（88%→73%）是无对照的时间观察，因果归属未建立。

4.1 第一页：一个字段，三种语义，93 倍的静默失真

早期设计中一个 count 字段被三条路径写入：召回 +1，蒸馏 +1，另一个子系统 +1。日常无人察觉，直到早期的一次全库审计给出 X 光片："原则"类条目平均计数 449，"用户原话"类平均 4.8。同一个字段，同一条衰减曲线，三种语义之间相差 93 倍；一个 1965 的单峰成为吞噬全部排序注意力的黑洞条目。需要说明：该倍数是类型均值之比，且受此单条主导；拆分前的逐条分布已不可重建（修复本身即拆分），故事后无法报告中位数。所有引用该字段的排序与清理逻辑，每天都在拿三种不可比的量做算术，而系统在报表上一切正常。

修复不是调参（调参救不了一个被三种语义共享的字段），是拆：三种语义各得各的字段、各配各的衰减常数、统一封顶 [0,100]。分离后的现场（2026-08 生产库实测）：类型间差距从 93 倍压缩到 2.2 倍（原则类均值 2.9 对原话类 1.3；统一语义下剩余差距是合法的），峰值被钉死在 100（图 4）。




图 4 | 证据 A：计数器的语义失真与分离修复（生产库实测）。

左：分离前，同一 count 字段被召回/蒸馏/第三子系统三路写入，"原则"类均值 449 与"原话"类均值 4.8 相差 93 倍，单条峰值 1965 构成黑洞（违 I3）。
右：拆分字段并封顶 [0,100] 后，统一语义下类型间差距 2.2 倍（合法差距），峰值被钉死。

4.2 第二页：病中报 0.999 的仪表盘

早期用全局比值评估记忆质量，常年稳定在 0.999 量级，健康得令人不安。我们一度把它当成绩。根因排查发现：它是对边型做比值，从未统计真实结构，因此从不跟踪库的健康。具体地，早期度量是 $\text{coherence} = (\text{total_links} - \text{contradict}) / \text{total_links}$ ；由于 contradict 边在全库极少，该比值长期钉在 1 附近（0.9996，显示为 0.999），在库持续恶化时依旧报绿。修正后的度量统计的是驻波之间真实的 reinforce 密度： $\text{coherence} = \log_{1p}(d) / \log_{1p}(3)$ ，其中 $d = 2 \times (\text{去重的强化边对}) / (\text{驻波节点数})$ ，只在驻波池内计算。同一个库，修正后读到 0.101（此处 $d \approx 0.15$ ）。除数 3 是经验归一化常数，且分数在 $d=3$ 处饱和；该度量宜作序数解读，不宜作基数解读。

结构盲视的度量，最危险的性质不是不准，而是系统一路变病、报告始终报绿。仪表盘亮绿灯，不代表车没坏；可能只代表仪表盘坏了。图 5 给出修复前后对照。度量应当是镜子——只反映，不逢迎；0.999 那面镜子结构盲视：它照的是镜头，不是路。




图 5 | 证据 B：病中报 0.999 的仪表盘。

左：早期全局"质量"比值，对边型做比值、从不统计真实结构，常年稳定 0.999——健康得令人不安。右：改数真实结构后的结构感知读数 0.101（与左侧量纲不同，不可直接比较）。结构盲视的度量最危险之处不是不准，而是给出虚假的安心：0.999 那面镜子量的只是边的比值，从不是记忆的真实结构。


4.3 第三页：承重的记忆在热度口径下可能得零分

全库结构审计：88% 的原话条目是孤岛：零派生边围绕。操作上，我们把 $\sigma = 0$ （无任何锚定入边）的原话条目记为一处孤岛；孤岛占比是对原话队列的直接计数（用户原话 67.8%， $n=5,956$ ；AI 原话 82.6%， $n=3,173$ ；2026-08 实测）。它们不是垃圾，恰是根。两个真实例子（轻度改写脱敏）：

其一，一条关于决策风格的自述：「他的风险定价方式：不是算最坏结果，而是找最小收获。」十几个字，无任何派生围绕，在一切计数器上为 0。它此后的价值不依赖被检索；它是一个人判断方式的底色，未来的某个决定会以它为根据，而任何热度度量都看不见它。

其二，一句关于老宅屋顶的琐碎闲谈，入库后三个月无人问津、零派生、零计数，直到一条后来相当重要的判断生成时，它成为唯一根据。检索热度在那三个月里对它的评估始终是：没有价值。

这就是 I2 的全部理由：根节点天生冷门，这是结构，不是异常。按热度触发的清理，可能删掉一个后来才成为关键判断唯一根据的根；而且删完之后，仪表盘还会变得更绿。而分离修复后的跟踪给出了这页病历的尾声：早期审计时孤岛占比 88%，至本文写作时已降至 73%（用户原话 67.8%、AI 原话 82.6%，2026-08 生产库实测，n=9,129）；15 个百分点的下降不是清理之功，恰是放任生长之功：约一千四百条原话（约 9,100 条队列上的 15 个百分点）在无人干预下自然长出了派生。桥梁不仅在图纸上，它在生长（图 6）。






表 3：病历总览——症状、铁证、违反的不变量与修复现场

病历	症状	铁证（生产库实测）	违反	修复	修复后现场
§ 4.1	一个字 段三种 语义	类型间均值差 93 倍（449 vs 4.8），单条峰值 1965 成黑洞	I3	拆字段，各配衰减，封顶 [0,100]	差距 93→2.2 倍，峰值钉死 100
§ 4.2	病中报 健康	虚报 0.999；结构感知口径读 0.101	不违反 I0 – I3（四条全过而度量照瞎）	改数真实结构（驻波间强化密度）	现在跟踪库状态
§ 4.3	热度错 杀根节 点	审计 88% 原话为孤岛（现值 73%），含关键判断的唯一根据	I2（写入时 1 – 10 分另属 I0 前置错杀）	代谢改生命周期触发，条目级联	孤岛占比 88→73%，约 1400 条原话持续派生

三页病历，两条失效轴。§ 4.1 与 § 4.3 是分离失效（I3、I2），各自可追溯到一次善意的、省事的干预。§ 4.2 属于另一条轴：不变量管的是信号分离，不是度量效度：结构盲视的度量四条不变量全过，却什么也没量到。我们把它记为独立的故障类：体检框架还必须验证"度量数的是它声称在数的东西"（见 § 5 第七条设计法则）。

5. 设计法则（方法的应用推论）

1. 浓度是数据，排序是服务，代谢是生命周期：三个信号三套机制，物理上分字段。

2. 计数器永不写回数据：算法过程可以推倒重算，被它改过的数据回不来。
3. 浓度在正确的作用域内测量：跨语义域数边，数出的是扇出。
4. 代谢以条目为单位级联，触发看生命周期；低频不等于过期。
5. 同字段异义是定时炸弹，拆分要趁早——晚拆一天，脏值多一天。
6. 一切重要性度量必须能通过行为静默检验。
7. 度量先过效度关：它数的必须是你声称它在数的东西。结构盲视的度量可以通过全部不变量，却什么也没量到。

6. 工具：两个当天可用的自查方法

行为静默检验 (Silence Test)： 停止系统一切召回行为 T 天（或离线重放历史而不更新任何持久计数），重新计算你的"重要性/质量/浓度"度量。数值纹丝不动，你测的是数据；数值漂移，你测的是热度：一份被行为污染的体检报告。成本： T 天耐心，几乎为零。

RAG 判别（更粗暴的一刀）： 把你的"记忆层"整层换成一台足够好的搜索引擎。先声明一个工作负载与判定标准；若系统行为在该标准下无实质差异，那么按此口径衡量，它就只是检索，不是记忆——记忆之为记忆，需存在查询之外的证据：浓度在无人检索时依然生长，代谢在无人观察时依然发生，某些记忆在未被询问时仍塑造着模型的行为。

静默检验日操作手册（五步，半天可完成）：

1. 快照当前全部"重要性/质量/浓度"度量值；
2. 冻结一切召回路径 T 天，或离线重放历史对话，但拦截所有对持久计数的写回；
3. 重新计算同一组度量，逐项对比快照；
4. 凡漂移项即行为污染项，标记其上游写入路径（那通常是 $\partial s / \partial \text{access} > 0$ 的正反馈源头）；
5. 公布结果，无论好坏。通过 I1 的系统应当零漂移。一个诚实的边界：零漂移只隔离了由访问驱动污染；来自其他更新路径的污染需另行控制，方可主张独立性。我们把这条边界落到实处：在自己约 3.8 万节点的库上，浓度 σ 与访问计数呈弱相关但非零（Pearson 0.24, $n \approx 37,000$ 活跃节点）。这一残余不是写路径，而是共同的结构成因；结构中心的节点同样更易被检索，相关性按类型剧烈波动（-0.17 到 +0.50）。plan 类节点内 +0.50 我们如实报告：在该类型内，浓度与访问目前不可分离，与"plan 类节点既结构中心又常被召回"相容。我们如实陈述，不做修剪。即为佐证。决定性证据仍在公式：任何访问计数都不进入 σ 的计算，而 I1 约束的正是这条写路径，不是相关性。一个诚实的边界：分母 p_{99} 是库级统计量，因此 σ 是库内相对量：即使节点自身入边不变，库增长时它的 σ 也可能漂移。 σ 比较的是同一库、同一时期的条目，不跨库比较。

我们建议维护者们给自己定一个"静默检验日"，结果无论好坏欢迎引用本框架报告；这个领域缺的不是新机制，是对旧机制的第一次体检。

7. 讨论：局限、效度威胁与为何不做 benchmark

n=1 单系统、单用户语料的纵向数据；无跨系统 benchmark（具体首试方案见下）；"浓度"以库级 p99 归一，会随库增长漂移，跨库或跨期比较需重新归一；且依赖系统内关联边结构，跨系统迁移需适配；证据来自失败复盘，存在幸存者叙述偏差的可能；我们判断不改变结论方向，但如实标注；单用户语料以私人对话为主，跨领域泛化未验证；"一条记忆的一生"为推演示例，各环节均有对应生产证据（§ 4），但时间线为合成。

为何不做跨系统 benchmark？三个诚实理由：其一，本文是单一系统的经验记录，跨系统试验属未来工作，不是本文检验的主张；其二，主流基准（如 LOCOMO [13]）度量的是问答准确率，而本文的诊断对象是信号结构；被测系统可以在基准上得分良好，同时违反全部四条不变量（§ 4.2 的 0.999 仪表盘正是这种"高分病态"）；我们提议的未来工作恰是把静默检验本身指标化：以"停止召回 T 天后重要性度量的漂移量"作为可跨系统比较的记忆健康度指标（ $\text{drift} \approx 0$ 为通过），这不需要任何训练算力，只需要诚实。第一个可做的对照试验：在一个开源实现（Mem0 或 Zep）上跑五步静默检验日并报告漂移量。

数据与工件可用性：本文全部聚合统计（计数分布、孤岛占比、修复前后对照）以图形式收录于本文及公开预印本（<https://doi.org/10.5281/zenodo.23068930>）；原始语料因隐私永不发布；静默检验操作手册（§ 6 五步）为公开工件，可自由复用与引用，无需授权。

伦理说明：语料来自作者本人的单人对话系统；所引语句均经作者本人同意使用。

8. 结论

最后是修复后系统的状态。拆分信号之后：类型间失真从 93 倍收敛到 2.2 倍，计数峰值钉死在 100；质量度量改为纯结构公式，改数真实结构而非边比值；88% 的孤岛原话至今安在，其中若干仍在持续派生。值得强调的是：这三处修复没有引入任何新的"聪明算法"（没有新模型、没有新打分器、没有学习到的权重），只是把三个被混用的职责分开，让浓度与代谢重新由数据自身决定。仅此而已。

而我们更想留在读者心里的，是一个不太舒服的判断：只要行业继续人为干预 LLM 的记忆，用打分代替沉淀，用裁决代替代谢，绕过中间介质把人的查询直接接进记忆，这些遗留惯性带来的不是更好的记忆，而是继续手工干预下的退化。RAG 至少诚实地承认自己是一台检索器；给检索器套上记忆的名号、再亲手剪掉它查询之外的生命，是一种更隐蔽的替代：系统甚至不再知道自己在做什么。

写过这类加权、阈值或裁决提示词的维护者，在这个意义上正是这种退化的执行者。好消息是，体检表放在 § 6：五步，半天，今天就能开始。

三个信号在我们系统里已经分开存储。也建议维护者检视自己的系统：很多可能会发现，那个指标一直在跟踪检索行为，而不是记忆本身。

参考文献

- [1] Park, J.S., et al. *Generative Agents: Interactive Simulacra of Human Behavior*. arXiv:2304.03442, 2023.
 - [2] Chhikara, P., et al. *Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory*. ECAI 2025 / arXiv:2504.19413.
 - [3] Mem0 Team. *Memory Eviction and Forgetting in AI Agents*. mem0.ai/blog, 2026.
 - [4] mem0ai/mem0, GitHub Issue #5330: Memory Access Frequency Tracking and Lifetime-Based Cleanup.
 - [5] Abdollahpouri, H., Burke, R., & Mobasher, B. *Controlling Popularity Bias in Learning-to-Rank Recommendation*. RecSys 2017.
 - [6] Rasmussen, P.S., et al. *Zep: A Temporal Knowledge Graph Architecture for Agent Memory*. arXiv:2501.13956.
 - [7] Orogat, A., & Mansour, E. *Is Agent Memory a Database? Rethinking Data Foundations for Long-Term AI Agent Memory*. arXiv:2605.26252, 2026.
 - [8] Roediger, H.L., & Karpicke, J.D. *Test-Enhanced Learning: Taking Memory Tests Improves Long-Term Retention*. Psychological Science, 2006.
 - [9] Rasch, B., & Born, J. *About Sleep's Role in Memory*. Physiological Reviews, 2013.
 - [10] Lewis, P., et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. NeurIPS 2020.
 - [11] Zhong, W., et al. *MemoryBank: Enhancing Large Language Models with Long-Term Memory*. AAAI 2024.
 - [12] Packer, C., et al. *MemGPT: Towards LLMs as Operating Systems*. arXiv:2310.08560, 2023.
 - [13] Maharana, A., et al. *Evaluating Very Long-Term Conversational Memory of LLM Agents*. ACL 2024.
-