

记忆的浓度、排序与代谢：长期运行智能体记忆系统中三个被混用的信号

赵宝峰

独立研究者

Salience, Ranking, and Metabolism: Three Conflated Signals in Long-Running Agent Memory Systems

摘要

长期运行的智能体记忆系统普遍把"重要性"当成单一信号。我们论证它其实是三个被混用的信号，而这一混用是结构性的设计错误，而非实现细节。一条 2023 年为模拟表演写的打分公式（relevance、recency 与 importance 的加权求和），未经检验地进入生产，让"重要性"的三个职责（沉淀、排序、退役）在同一个信号里相互干扰。本文的出发点是一条服务链：记忆为 LLM 服务，LLM 为人服务。抽掉中间环节、让记忆直接服务人的查询，我们认为再复杂的系统也会向 RAG 漂移。基于一个自 2026-03 起连续运行约 7 个月、约 38,000 条记忆条目（皮层节点）、148,000 条关联边（2026-08 审计快照，现库约 108,000 条）的真实系统运维数据，论证"重要性"至少是三个最好分开的正交信号：浓度（数据的固有属性）、排序（查询时刻的算法服务）、代谢（条目的生命周期退役）。我们记录三类混用的生产故障：计数器内部的 93 倍语义偏斜、一个结构盲视的质量度量（报 0.999，而同库结构感知一致性读 0.101）、以及 88% 的原始记忆为"孤岛"（写作时 73%，不加清理仍在下降）却含结构上最核心的根。检索侧的压力可测：访问分布基尼系数 0.960，Top 1% 节点吸走 51.9% 的全部访问。我们提交一套带四条不变量（I0 - I3）的信号分类学、七条设计法则，以及两个当天可执行的自查工具（行为静默检验、RAG 判别）。本文不宣称 benchmark 优势；证据全部来自作者自己的失败；这一点上，我们数据充足。

关键词：智能体记忆；信号分离；正反馈偏差；RAG；记忆治理；立场论文

Abstract (EN). Long-running agent memory systems commonly treat "importance" as a single quantity. We argue that it conflates three distinct signals, and that the conflation is a structural design error rather than an implementation detail. A scoring formula written in 2023 for a simulation demo (relevance plus recency plus importance) moved into production unexamined, letting the three jobs of "importance" (sedimentation, ranking, retirement) interfere within a single signal. Our position rests on a service chain: memory serves the LLM; the LLM serves the human. And memory must be memory: self-describing and self-metabolizing, its salience and retirement decided by data and lifecycle rather than one-shot human-delegated verdicts (Invariant I0). Skip the middle link and even the most elaborate memory system drifts toward RAG. Since March 2026, about seven months of production telemetry on a single conversational system (~38K memory items, ~148K association links at the 2026-08 audit; the live store now ~108K links), we argue that "importance" is at

least three orthogonal signals best kept physically separated: salience (intrinsic to the data), ranking (a query-time service), and metabolism (lifecycle retirement). We document three production failures of conflation: a 93× semantic skew inside one counter, a structure-blind quality metric reporting 0.999 while the store's structure-aware coherence read 0.101, and 88% of raw memories being "islands" (73%, still declining without cleanup), yet containing the most structurally central roots. The retrieval-side pressure is measurable: an access-distribution Gini coefficient of 0.960, with the top 1% of nodes absorbing 51.9% of all accesses. We contribute a signal taxonomy with four invariants (I0 – I3), seven design laws, and two same-day audit tools (the Silence Test and the RAG Test). No benchmark supremacy is claimed; all evidence comes from our own failures, of which we have plenty.

1. 引言：记忆为谁服务——RAG 的遗产问题

「思维能在下次生效吗？——可是你上次整理了什么，你自己都忘了。」

——本系统语料原话（轻度改写脱敏）

先回答一个比打分公式更根本的问题：记忆为谁服务？

人的记忆不为查询而建。一件事沉下去，多年后自发浮现，以气味、口吻与处理惯性。人遗忘的方式是活着：不是执行删除策略，而是被后来的生活慢慢覆盖。人的记忆没有索引，也从不给自己的回忆打分。

LLM 相反：默认状态下每一次对话都从零开始。它的记忆无法自然生长，只能被建设。

我们给出的立场是一条服务链：记忆为 LLM 服务，LLM 为人服务。一旦抽掉中间一环（让记忆直接服务于人的查询），那么无论系统包装得多复杂（抽取、合并、图谱、分层），我们主张它本质上仍只是一个 RAG [10]：一个人查、一台搜、把结果塞进上下文让模型当粘合剂。RAG 作为工具无可指摘；作为记忆架构，它是类别错误：它让记忆的全部生命都发生在检索时刻、由查询塑造，记忆成了索引，模型成了管道。

人脑记忆与硅基记忆是两种介质；介质之间需要桥梁，而不是直接接线。把人的文档直接拼接进上下文是接线；把原话沉淀为结构、让派生围绕锚点收敛、让因果链可溯、以模型能生长的方式重建过去，这才是桥梁。我们对人为干预的态度同此：记忆的结构应当被认出来，而不是被造出来。桥梁要立得住，至少需要三种不同的材料，即本文的三位主角。

服务链回答了记忆为谁服务；还有第二个同样根本的问题：记忆凭什么成立？我们的副论点是：让 LLM 拥有记忆，前提是让记忆本身就是记忆，而非被人为干涉的记忆。浓度不是谁打出来的分数，是数据自己的形状——即领域所称的 importance/poignancy（重要性）打分（参照 [1]）；代谢不是谁执行的删除策略，是记忆在自己生命周期里的生老病死——即领域文献所称 memory management（记忆管理）中遗忘与合并的一侧（参照 Mem0 的

UPDATE/DELETE 操作 [3])。数据库的语义是二值的：一条记录或者在，或者不在，动词只有增删改查；记忆的语义是活的（生长、收敛、退役、循环），全部由数据内生决定：数据决定浓度，数据决定代谢。写入时请 LLM 打一个 1 - 10 分，或请 LLM 裁判裁决删留，都是在数据与它自身的重量之间插入一个外来判决，这是人工干涉的记号。并行工作 [7] 问"智能体记忆是不是数据库"；本文的回答是：不是，并且给出它是什么的正面纲领：一个自洽的、有代谢的记忆生命体。

行业当前的默认做法仍停留在检索时代：把记忆当成一件为查询而优化的东西。RAG 心智的具体化石，就是那条从 demo 继承的公式。2023 年，一个由 25 个 LLM 智能体组成的小镇模拟（Generative Agents [1]）提出了如今几乎是行业默认的记忆检索公式：

$$\text{score} = \text{relevance (余弦相似度)} + \text{recency (指数衰减, 因子 0.995, 按最近访问计)} + \text{importance (写入时 LLM 打 1 - 10 分)}$$

这个公式为一场模拟表演而写，却成了大量生产系统的骨架。问题不在求和（加权融合本身无辜），而在于它悄悄让同一个信号同时打三份工：决定一条记忆有多厚（它是不是被大量后续内容围绕的锚点）、决定这次召回它排第几（此刻合不合适）、并间接决定它还能活多久（清理逻辑普遍引用计数/热度类输入）。把三个信号塞进一个字段，就像把心率、车速和油耗刻进同一块表：指针在动，但已无法说明自己在报哪一项。

本文论点：这不是实现细节的粗糙，是结构性的类别错误。贡献四项，每项均可独立检验：

- C1（论点） 记忆服务链的重新定位：记忆为 LLM 服务、LLM 为人服务；记忆直接服务人的查询即趋向坍塌为 RAG；
- C2（分类学） 浓度/排序/代谢三信号的形式化区分、记忆自洽原则与四条不变量（I0 - I3）；
- C3（证据） 三条生产故障记录（93 倍字段异义、0.999 假健康、88% 孤岛根节点）与分离后的现场读数（93→2.2 倍）；
- C4（工具） 两个当天可执行的自查工具：行为静默检验、RAG 判别。

全文论证路线：§ 2 相关工作定位病灶 → § 3 方法给出诊断框架 → § 4 案例研究提交病历 → § 5 - § 6 给出应用推论与自查工具 → § 7 - § 8 划定边界并收束。最后，防三处误读。本文不反对检索；检索是记忆合法的取用动作，我们反对的只是让它兼任唯一的裁判；本文不反对打分；分数可以作为排序层的输入，不能充当浓度的代理，也不能充当代谢的终止判据；本文不提交新架构；交付的是体检框架与不变量，任何现有系统都可以在不推倒重来的前提下自检与修复。

2. 相关工作：三种继承者与一股批评浪潮

(a) 教科书形态——检索即强化。Generative Agents [1] 的新近度按最近访问衰减：被检索的记忆获得新近度刷新，从而更容易被再次检索。这是推荐系统领域被充分研究过的正反馈/流行度偏差 [5]，在推荐系统里它的终点叫信息茧房；搬进记忆系统，终点是记忆茧房：一个只剩自己爱 recall 之事物的模型。据我们检索所及，这一批评在智能体记忆语境中尚未被正式提出。

(b) 融合形态——一个裁判管三件事。Mem0 [2] 每次写入做两遍 LLM 调用：抽取候选事实，再由 LLM 裁判对向量相似邻居做出 ADD / UPDATE / DELETE 裁决。浓度判断（新事实多重要）、代谢决策（旧事实该不该死）、留存材料（留什么给检索）融合在同一次裁决里，且由"相似性能检索到谁"这个偶然因素触发。公允地说，业界已开始正视这一痛感：Mem0 团队已在讨论淘汰与遗忘 [3]，社区在提议按访问频率做生命周期清理 [4]。在这类工作开始把检索衰减与淘汰分开处理之处，本文的独特贡献是将其一般化为带不变量 (I0 – I3) 的三信号分类学，并为每一种故障模式提供纵向生产证据；问题已被承认，但药方尚未形成。

(c) 半分离形态——最接近，差一步。Zep [6] 的双时态边让被取代的事实失效而非删除（历史保全），是对代谢最清醒的处理；但其检索排序仍是 relevance + recency + episode usage；使用频率直接进排序，行为对度量的污染仍在。MemGPT [12] 普及了分层记忆管理（工作上下文与外存之间的分页），但其淘汰同样读取新近度与使用量。

(d) 正在形成的批评浪潮。并行工作 "Is Agent Memory a Database?" [7] 已批评现有打分是"检索时刻的局部启发式"。我们同意诊断，并向前两步：给出完整的三信号分类学与不变量，以及生产级纵向故障证据。一股批评的浪潮正在形成；本文为它提供一个框架。

(e) 一个预设的反驳：为什么不干脆请 LLM 打分？最自然的辩护是：让 LLM 在写入时给重要性打分 ([1] 的 1 – 10 分)，或在更新时当裁判 ([2])，不就有"重要性"了吗？三个理由都不行。其一，这是 I0 违例：一次性外部判决代替了数据自身的重量，而判决者看不到未来，写入那天无人知道哪条原话三个月后会成为关键判断的唯一根据 (§ 4.3)。其二，裁判是检索的囚徒：LLM 裁判只能看见向量相似性能送到它面前的邻居，于是"什么算重要"被"什么相似"绑架 (§ 2b)。其三，判决不可代谢：分数一旦写下便成为永久标签——实质上是一次性的在/不在判决。

表 1：三种继承者 × 三信号的处置矩阵

系统	浓度（固有属性）	排序（查询服务）	代谢（生命周期）
Generative Agents [1]	无独立信号（写入时 LLM 打 1 – 10 分，一次定终身）	relevance + recency（访问刷新）+ importance 混合	无代谢机制
Mem0 [2]	与代谢、留存融合于同一次 LLM 裁决	向量相似 + 裁决结果	同一裁决内 DELETE（由相似邻居触发）
Zep [6]	无独立信号	relevance + recency + usage（行为入序）	双时态失效而非删除（最接近 I2）

系统	浓度（固有属性）	排序（查询服务）	代谢（生命周期）
本文	数据固有属性，作用域内测收敛，不受行为影响	有界 [0,100] + 衰减，绝不写回数据	条目级级联，生命周期触发，不看热度

3. 方法：三信号定义、不变量与正反馈分析

记号：以 $\sigma(x)$ 记条目 x 的浓度， $\rho(x)$ 记 x 的排序层分数， $\mu(x)$ 记 x 的代谢状态；三者的定义域与写入者互不相同，这正是本节的全部主张。关于 ρ ：存储的分数只是每次查询排序的输入，查询时与查询相似度融合；持久分数本身不携带查询。

定义 1（浓度 / Salience）：条目 x 的结构属性（以库内相对方式度量）——"多少派生内容以 x 为锚点收敛"，且必须在正确的作用域内测量（跨语义域计数得到的是扇出噪音，不是收敛）。关键性质：不被召回行为影响。它是数据的形状，不是数据的热度；无人检索时，它依然生长。具体实现中，我们把浓度度量为归一化收敛密度： $\sigma(x) = \log_{1p}(\text{锚定入边的物理量}) / \log_{1p}(p_{99})$ ，且只统计锚定类边型（raw_basis、ai_basis、derived_from）；召回驱动的边按构造被排除，故 σ 在任何召回行为下保持不动。

一个诚实的边界：分母 p_{99} 是库级统计量，因此 σ 是库内相对量：即使节点自身入边不变，库增长时它的 σ 也可能漂移。 σ 比较的是同一库、同一时期的条目，不跨库比较。

定义 2（排序 / Ranking）：查询时刻的算法服务输出；有界计数（如 [0,100]）叠加遗忘曲线式衰减是合法实现。关键性质：可随时整体重算、只服务消费方、绝不写回数据。我们的实现：艾宾浩斯式分数 $\rho = \text{count_norm} \times \exp(-\Delta t / S)$ ， $S = 7 \times (1 + \text{count})$ ，并硬性封顶 $\text{count} \leq 100$ 。其中 count 为召回计数（封顶 100）， count_norm 为该计数按封顶归一到 [0,1]， Δt 为距上次召回的天数， $S = 7 \times (1 + \text{count})$ 与 Δt 同为天单位（艾宾浩斯遗忘曲线用于 LLM 记忆的做法承自 MemoryBank [11]）。


定义 3（代谢 / Metabolism）：生命周期决策，以条目为单位级联（原话退役，其派生物与关联边一并退役）。关键性质：触发条件是生命周期事件，不是任何热度或排序分数。低频 $\neq$ 过期——低频是根节点的天性，不是它的罪。我们的实现：退役是一次软状态标记，以条目为单位级联；它只读生命周期事件，绝不读任何计数器。图 1 概括了三个域与隔开它们的墙。

三分离在这里还有一条更深的注脚。排序的新近度衰减把时间当作测量单位，这没有错，钟表是排序层的合法工具；但浓度不是时钟的函数，它是互动的沉积，由多少派生围绕收敛构成，与墙上时钟无关。把时间还给钟表，把互动还给记忆：这正是排序与浓度在物理上必须分家的那道缝。

不变量：

- I0（不代言）：记忆的持久属性（浓度、存活）不得由写入时刻的一次性外部判决（如 LLM 打分、LLM 裁判裁决）赋值；它们是数据与生命周期的内生属性；
- I1（不污染）：排序信号的任何变化不得改变浓度与数据本身；
- I2（不误杀）：代谢不得以排序/热度分数为唯一触发条件；
- I3（不同义）：同一物理字段不得承载多种语义。


正反馈草图（图 2）（为什么混用必然恶化）：设排序分 s 依赖新近度 r ， r 随时间衰减但随访问刷新，则 $\partial s / \partial \text{access} > 0$ ，而 access 概率又随 s 上升——自增强回路。只有把“访问”严格关进排序层、并禁止它写回任何持久字段（I1），回路才被物理切断。这不是工程洁癖，是切断反馈回路的最低结构要求。这股压力的大小是可实测的：本系统当前（三分离之后、有界封顶的）排序层访问分布：25,705 个节点，访问计数基尼系数 0.960（图 3），Top 1% 节点吸走 51.9% 的全部访问，Top 10% 占 96.9%，85.8% 的节点零访问。这组数字的正确解读是：排序层的赢家通吃本身合法；它被关在服务层内、随时可整体重算；数字的全部意义在于警示——这样一股分布，若被写进任何持久字段，就是对 85.8% 零访问节点的淘汰判决，其中多数是根。



左：混用形态下，检索刷新新近度（Generative Agents 的 0.995 衰减按最近访问计）， $\partial s / \partial \text{access} > 0$ 构成自增强回路，无稳态与再平衡机制时终局为赢家通吃。右：I1 将访问敏感性关进服务层并禁止写回持久字段，回路被物理切断；对照人脑：测试效应的强化有突触稳态与睡眠巩固再平衡配平——“要学就学全”。

图 2：正反馈回路：检索抬高访问计数，访问计数抬高排序，排序又抬高检索——混用喂养的计数器回路。

访问量累计占比



这样一股分布若被写进持久字段 = 对 85.8% 零访问节点的淘汰判决
(多数是根) ——此即 I1 存在的理由

图 7 | 排序层访问分布的洛伦兹曲线 (生产库实测, 2026-08)。

25,705 个节点的访问计数分布：基尼系数 0.960，Top 1% 节点占全部访问的 51.9%，Top 10% 占 96.9%，85.8% 的节点零访问。注意：该分布测于三信号分离之后——排序层的赢家通吃是合法的（有界、可重算、不写回）；本图的意义是量化正反馈回路的压力大小，并说明为何任何持久字段都不得引用此类分布（不变量 I1）。

图 3：访问分布洛伦兹曲线：基尼 0.960；Top 1% 节点吸走 51.9% 的全部访问（Top 10%，96.9%）。

一条记忆的一生（推演，图 4）。把三个定义放进同一条时间线，差别立刻具体。第 0 天，一句原话入库：接线式世界里它被 LLM 打了 5 分，从此带着终身标签生活；桥梁式世界里它没有分数，只有身份——原话锚点。第 30 天，它碰巧被召回两次：接线式里新近度被刷新、排序分上涨，开始吸引更多召回；桥梁式里排序分同样上涨，但这一切被关在服务层，它的浓度纹丝不动，依旧零派生围绕。第 90 天，无人再问起：接线式里它的分数随衰减归零，进入清理候选；桥梁式里它同样“凉了”，但凉的只是排序，不是生存资格。第 120 天，一条新判断需要根据，发现唯一锚点是它：接线式世界在第 100 天已按热度把它删了，判断失去根据、仪表盘全绿；桥梁式世界里它被派生围绕，浓度第一次真正生长，从孤岛成为根。同一条记忆，两种命运；差别不在任何一步的算法优劣，在于三件事是否分家。




图 4：一条记忆的一生：第 0 天原话入库；第 30 天偶然被检索两次；第 90 天无人问津、排序分衰减；第 120 天新判断以它为唯一锚点，浓度第一次真正生长。

与人类记忆的对照（与一条诚实的边界）。人脑的检索确实会强化记忆；测试效应是认知心理学的经典结果 [8]；那么 I1"禁止访问写回数据"是否反生物？不是，是生物学被引了一半：人脑的强化发生在独立的突触基质中，受稳态再平衡约束，并在睡眠巩固里被整体重新配平 [9]：强化有界、有回账、有再平衡。软件计数器只有强化、没有稳态：无界的正反馈正是 § 2a 的记忆茧房。I1 的准确读法因此不是"不许学生物"，而是"要学就学全"：访问敏感性可以存在于排序层（有界、衰减、可重算），持久层必须保持行为无关，除非引入带稳态与再平衡的独立机制。




图 1 | 三信号架构：数据域、服务域、生命周期域三域分立。

浓度 σ 居数据域（结构固有，行为无关）；排序 ρ 居服务域（有界+衰减，可重算，禁止写回，I1 墙）；代谢 μ 居生命周期域（条目级联，热度禁入，I2 墙）；I3 禁止字段混语义；I0 禁止外部判决代言持久属性。虚线红叉为被 I1 切断的“访问写回”正反馈路径。

图 1：三个物理分离的信号：浓度（数据固有）、排序（查询时刻服务）与代谢（生命周期退役），各自持有独立的存储与更新路径。

4. 案例研究：单一生产系统的故障记录 (n=1)

系统背景：自 2026-03 起连续运行约 7 个月的对话式智能体记忆系统，双库结构（原话层 + 蒸馏层），约 38,000 条记忆条目（皮层节点）、148,000 条关联边（2026-08 审计快照；现库约 108,000 条）。以下数字均来自生产库真实回放。

表 2：证据时间线（单一库）。

时点	发生了什么	队列
早期审计（修复前）	全库审计发现 93 倍字段语义偏斜与 88% 孤岛占比	审计时的整层原话
修复后（字段拆分、封顶 [0,100]）	类型间差距 93 倍 $\rightarrow$ 2.2 倍；峰值钉死 100	同字段重测
2026-08（修复后快照）	孤岛占比 67.8%（用户，n=5,956） / 82.6%（AI，n=3,173）；合计 73.0%（n=9,129）；基尼 0.960（n=25,705）	当月原话

时点	发生了什么	队列
2026-10（现库）	关联边约 108,000；原话层约 13,364（用户 6,289 + AI 7,075）	当前

术语表（本文用法）：*皮层（cortex）*——蒸馏节点库（约 3.8 万节点）；*原话层*——逐字话语；*蒸馏层*——派生节点；*锚点*——派生内容收敛于其上的节点；*驻波池*——带已完成向量且权重超过活跃门的活皮层节点；*活跃门*——允许节点进入该池的权重阈值。

本节读法：这些是来自单一系统的"识别与处置记录"，不是受控试验。把被三种语义共用的字段拆开，跨类型差距必然收缩（93 倍→2.2 倍部分是拆分的定义性后果）；峰值停在 100 也是因为封顶即 100。孤岛占比变化（88%→73%）是无对照的时间观察，因果归属未建立。

4.1 第一页：一个字段，三种语义，93 倍的静默失真

早期设计中一个 count 字段被三条路径写入：召回 +1，蒸馏 +1，另一个子系统 +1。日常无人察觉，直到早期的一次全库审计给出 X 光片："原则"类条目平均计数 449，"用户原话"类平均 4.8。同一个字段，同一条衰减曲线，三种语义之间相差 93 倍；一个 1965 的单峰成为吞噬全部排序注意力的黑洞条目。需要说明：该倍数是类型均值之比，且受此单条主导；拆分前的逐条分布已不可重建（修复本身即拆分），故事后无法报告中位数。所有引用该字段的排序与清理逻辑，每天都在拿三种不可比的量做算术，而系统在报表上一切正常。

修复不是调参（调参救不了一个被三种语义共享的字段），是拆：三种语义各得各的字段、各配各的衰减常数、统一封顶 [0,100]。分离后的现场（2026-08 生产库实测）：类型间差距从 93 倍压缩到 2.2 倍（原则类均值 2.9 对原话类 1.3；统一语义下剩余差距是合法的），峰值被钉死在 100（图 5）。




图 5：计数器语义失真：单字段承载多种语义，拆分前产生 93 倍跨类型偏斜（统一语义下残余 2.2 倍）。

4.2 第二页：病中报 0.999 的仪表盘

早期用全局比值评估记忆质量，常年稳定在 0.999 量级，健康得令人不安。我们一度把它当成绩。根因排查发现：它是对边型做比值，从未统计真实结构，因此从不跟踪库的健康。具体地，早期度量是 $coherence = (total_links - contradict) / total_links$ ；由于 contradict 边在全库极少，该比值长期钉在 1 附近（0.9996，显示为 0.999），在库持续恶化时依旧报绿。修正后的度量统计的是驻波之间真实的 reinforce 密度： $coherence = \log_{1p}(d) / \log_{1p}(3)$ ，其中 $d = 2 \times (\text{去重的强化边对}) / (\text{驻波节点数})$ ，只在驻波池内计算。同一个库，修正后读到 0.101（此处 $d \approx 0.15$ ）。除数 3 是经验归一化常数，且分数在 $d=3$ 处饱和；该度量宜作序数解读，不宜作基数解读。

结构盲视的度量，最危险的性质不是不准，而是系统一路变病、报告始终报绿。仪表盘亮绿灯，不代表车没坏；可能只代表仪表盘坏了。图 6 给出修复前后对照。度量应当是镜子——只反映，不逢迎；0.999 那面镜子结构盲视：它照的是镜头，不是路。




图 6：病中报健康的仪表盘：结构盲视一致性读 0.999（原始 0.9996），同库结构感知一致性读 0.101。


4.3 第三页：承重的记忆在热度口径下可能得零分

全库结构审计：88% 的原话条目是孤岛：零派生边围绕。操作上，我们把 $\sigma = 0$ （无任何锚定入边）的原话条目录为一处孤岛；孤岛占比是对原话队列的直接计数（用户原话 67.8%， $n=5,956$ ；AI 原话 82.6%， $n=3,173$ ；2026-08 实测）。它们不是垃圾，恰是根。两个真实例子（轻度改写脱敏）：

其一，一条关于决策风格的自述：「他的风险定价方式：不是算最坏结果，而是找最小收获。」十几个字，无任何派生围绕，在一切计数器上为 0。它此后的价值不依赖被检索；它是一个人判断方式的底色，未来的某个决定会以它为根据，而任何热度度量都看不见它。

其二，一句关于老宅屋顶的琐碎闲谈，入库后三个月无人问津、零派生、零计数，直到一条后来相当重要的判断生成时，它成为唯一根据。检索热度在那三个月里对它的评估始终是：没有价值。

这就是 I2 的全部理由：根节点天生冷门，这是结构，不是异常。按热度触发的清理，可能删掉一个后来才成为关键判断唯一根据的根；而且删完之后，仪表盘还会变得更绿。而分离修复后的跟踪给出了这页病历的尾声：早期审计时孤岛占比 88%，至本文写作时已降至 73%（用户原话 67.8%、AI 原话 82.6%，2026-08 生产库实测， $n=9,129$ ）；15 个百分点的下降不是清理之功，恰是放任生长之功：约一千四百条原话（约 9,100 条队列上的 15 个百分点）在无人干预下自然长出了派生。桥梁不仅在图纸上，它在生长（图 7）。



5. 设计法则（方法的应用推论）

1. 浓度是数据，排序是服务（领域词表中的记忆读取/检索排序环节，参照 Recency/Importance/Relevance 打分 [1]），代谢是生命周期：三个信号三套机制，物理上分字段。
2. 计数器永不写回数据：算法过程可以推倒重算，被它改过的数据回不来。
3. 浓度在正确的作用域内测量：跨语义域数边，数出的是扇出。
4. 代谢以条目为单位级联，触发看生命周期；低频不等于过期。
5. 同字段异义是定时炸弹，拆分要趁早——晚拆一天，脏值多一天。
6. 一切重要性度量必须能通过行为静默检验。
7. 度量先过效度关：它数的必须是你声称它在数的东西。结构盲视的度量可以通过全部不变量，却什么也没量到。

6. 工具：两个当天可用的自查方法

行为静默检验（Silence Test）：停止系统一切召回行为 T 天（或离线重放历史而不更新任何持久计数），重新计算你的"重要性/质量/浓度"度量。数值纹丝不动，你测的是数据；数值漂移，你测的是热度：一份被行为污染的体检报告。成本： T 天耐心，几乎为零。

RAG 判别（更粗暴的一刀）：把你的"记忆层"整层换成一台足够好的搜索引擎。先声明一个工作负载与判定标准；若系统行为在该标准下无实质差异，那么按此口径衡量，它就只是检索，不是记忆——记忆之为记忆，需存在查询之外的证据：浓度在无人检索时依然生长，代谢在无人观察时依然发生，某些记忆在未被询问时仍塑造着模型的行为。

静默检验日操作手册（五步，半天可完成）：

1. 快照当前全部"重要性/质量/浓度"度量值；
2. 冻结一切召回路径 T 天，或离线重放历史对话，但拦截所有对持久计数的写回；
3. 重新计算同一组度量，逐项对比快照；
4. 凡漂移项即行为污染项，标记其上游写入路径（那通常是 $\partial s / \partial \text{access} > 0$ 的正反馈源头）；
5. 公布结果，无论好坏。通过 I1 的系统应当零漂移。一个诚实的边界：零漂移只隔离了由访问驱动污染；来自其他更新路径的污染需另行控制，方可主张独立性。我们把这条边界落到实处：在自己约 3.8 万节点的库上，浓度 σ 与访问计数呈弱相关但非零（Pearson 0.24, $n \approx 37,000$ 活跃节点）。这一残余不是写路径，而是共同的结构成因；结构中心的节点同样更易被检索，相关性按类型剧烈波动（-0.17 到 +0.50）。plan 类节点内 +0.50 我们如实报告：在该类型内，浓度与访问目前不可分离，与"plan 类节点既结构中心又常被召

回"相容。我们如实陈述，不做修剪。决定性证据仍在公式：任何访问计数都不进入 σ 的计算，而 I1 约束的正是这条写路径，不是相关性。

我们建议维护者们给自己定一个"静默检验日"，结果无论好坏欢迎引用本框架报告；这个领域缺的不是新机制，是对旧机制的第一次体检。

7. 讨论：局限、效度威胁与为何不做 benchmark

n=1 单系统、单用户语料的纵向数据；无跨系统 benchmark（具体首试方案见下）；"浓度"以库级 p99 归一，会随库增长漂移，跨库或跨期比较需重新归一；且依赖系统内关联边结构，跨系统迁移需适配；证据来自失败复盘，存在幸存者叙述偏差的可能；我们判断不改变结论方向，但如实标注；单用户语料以私人对话为主，跨领域泛化未验证；"一条记忆的一生"为推演示例，各环节均有对应生产证据（§ 4），但时间线为合成。

为何不做跨系统 benchmark？三个诚实理由：其一，本文是单一系统的经验记录，跨系统试验属未来工作，不是本文检验的主张；其二，主流基准（如 LOCOMO [13]）度量的是问答准确率，而本文的诊断对象是信号结构；被测系统可以在基准上得分良好，同时违反全部四条不变量（§ 4.2 的 0.999 仪表盘正是这种"高分病态"）；我们提议的未来工作恰是把静默检验本身指标化：以"停止召回 T 天后重要性度量的漂移量"作为可跨系统比较的记忆健康度指标（ $\text{drift} \approx 0$ 为通过），这不需要任何训练算力，只需要诚实。第一个可做的对照试验：在一个开源实现（Mem0 或 Zep）上跑五步静默检验日并报告漂移量。

数据与工件可用性：本文全部聚合统计（计数分布、孤岛占比、修复前后对照）以图形式收录于本文及公开预印本（<https://doi.org/10.5281/zenodo.23068930>）；原始语料因隐私永不发布；静默检验操作手册（§ 6 五步）为公开工件，可自由复用与引用，无需授权。

伦理说明：语料来自作者本人的单人对话系统；所引语句均经作者本人同意使用。

8. 结论

最后是修复后系统的状态。拆分信号之后：类型间失真从 93 倍收敛到 2.2 倍，计数峰值钉死在 100；质量度量改为纯结构公式，统计真实结构而非边比值；88% 的孤岛原话至今安在，其中若干仍在持续派生。需要强调：这三处修复没有引入任何新的"聪明算法"（没有新模型、没有新打分器、没有学习到的权重），只是把三个被混用的职责分开，让浓度与代谢重新由数据自身决定。仅此而已。

而我们更想留在读者心里的，是一个不太舒服的判断：只要行业继续人为干预 LLM 的记忆，用打分代替沉淀，用裁决代替代谢，绕过中间介质把人的查询直接接进记忆，这些遗留惯性带来的不是更好的记忆，而是继续手工干

预下的退化。RAG 至少诚实地承认自己是一台检索器；给检索器套上记忆的名号、再亲手剪掉它查询之外的生命，是一种更隐蔽的替代：系统甚至不再知道自己在做什么。

写过这类加权、阈值或裁决提示词的维护者，在这个意义上正是这种退化的执行者。好消息是，体检表放在 § 6：五步，半天，今天就能开始。

三个信号在我们系统里已经分开存储。也建议维护者检视自己的系统：很多可能会发现，那个指标一直在跟踪检索行为，而不是记忆本身。

参考文献

- [1] Park, J.S., et al. *Generative Agents: Interactive Simulacra of Human Behavior*. arXiv:2304.03442, 2023.
- [2] Chhikara, P., et al. *Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory*. ECAI 2025 / arXiv:2504.19413.
- [3] Mem0 Team. *Memory Eviction and Forgetting in AI Agents*. mem0.ai/blog, 2026.
- [4] mem0ai/mem0, GitHub Issue #5330: Memory Access Frequency Tracking and Lifetime-Based Cleanup.
- [5] Abdollahpouri, H., Burke, R., & Mobasher, B. *Controlling Popularity Bias in Learning-to-Rank Recommendation*. RecSys 2017.
- [6] Rasmussen, P.S., et al. *Zep: A Temporal Knowledge Graph Architecture for Agent Memory*. arXiv:2501.13956.
- [7] Orogat, A., & Mansour, E. *Is Agent Memory a Database? Rethinking Data Foundations for Long-Term AI Agent Memory*. arXiv:2605.26252, 2026.
- [8] Roediger, H.L., & Karpicke, J.D. *Test-Enhanced Learning: Taking Memory Tests Improves Long-Term Retention*. Psychological Science, 2006.
- [9] Rasch, B., & Born, J. *About Sleep's Role in Memory*. Physiological Reviews, 2013.
- [10] Lewis, P., et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. NeurIPS 2020.
- [11] Zhong, W., et al. *MemoryBank: Enhancing Large Language Models with Long-Term Memory*. AAAI 2024.
- [12] Packer, C., et al. *MemGPT: Towards LLMs as Operating Systems*. arXiv:2310.08560, 2023.
- [13] Maharana, A., et al. *Evaluating Very Long-Term Conversational Memory of LLM Agents*. ACL 2024.

