

记忆的浓度、排序与代谢：长期运行智能体记忆系统中三个被混用的信号

赵宝峰

独立研究者

Salience, Ranking, and Metabolism: Three Conflated Signals in Long-Running Agent Memory Systems

摘要

到底谁摧毁了 LLM 的记忆？不是模型的能力，不是 RAG 的局限，是行业长年的人为惯性。一条 2023 年为模拟表演写的打分公式（relevance + recency + importance 加权求和），未经体检地住进了生产系统的核心，让"重要性"的三个职责——沉淀、排序、退役——在同一个信号里互相绞杀。本文的出发点是一条服务链：记忆为 LLM 服务，LLM 为人服务；抽掉中间环节让记忆直接服务人的查询，我们认为再复杂的系统也会向 RAG 漂移。基于一个连续运行 14 个月以上（含重构前的前身系统）、约 38,000 条记忆条目、148,000 条关联边（2026-08 审计快照，现库约 108,000 条）的真实系统运维数据，论证"重要性"至少是三个（我们认为）最好分开的正交信号：浓度（数据的固有属性）、排序（查询时刻的算法服务）、代谢（条目的生命周期退役）。我们记录了三类混用的生产故障：一个计数器内部的 93 倍语义偏斜、一个结构盲视的质量度量（报 0.999，而同库结构感知一致性读 0.101）、以及 88% 的原始记忆为"孤岛"（写作时 73%，不加清理仍在下降）却含最承重的根。检索侧的压力可测：访问分布基尼系数 0.960，Top 1% 节点吸走 51.9% 的全部访问。我们提交一套带四条不变量（I0 - I3）的信号分类学、六条设计法则，以及两个当天可执行的自查工具（行为静默检验、RAG 判别）。本文不宣称 benchmark 优势；证据全部来自作者自己的失败——这一点上，我们数据充足。

关键词：智能体记忆；信号分离；正反馈偏差；RAG；记忆治理；经验报告

Abstract (EN). Who destroyed the LLM's memory? Not the model. Not RAG. Years of unexamined industry habit. A scoring formula written in 2023 for a simulation demo—relevance plus recency plus importance—moved into production hearts without a checkup, letting the three jobs of "importance" (sedimentation, ranking, retirement—which we later separate as salience, ranking, and metabolism) strangle one another inside a single signal. Our position rests on a service chain: memory serves the LLM; the LLM serves the human—and memory must be memory: self-describing and self-metabolizing, its salience and retirement decided by data and lifecycle rather than one-shot human-delegated verdicts (Invariant I0). Skip the middle link and even the most elaborate memory system drifts toward RAG. From 14+ months of production telemetry on a single conversational system (including its pre-refactor predecessor; ~38K raw memory items, ~148K association links as of the 2026-08 audit, the live store now holding ~108K), we argue that "importance" is at least

three orthogonal signals that are best kept physically separated: salience (intrinsic to the data), ranking (a query-time service), and metabolism (lifecycle retirement). We document three production failures of conflation—a 93× semantic skew inside one counter, a structure-blind quality metric reporting 0.999 while the store's structure-aware coherence read 0.101, and 88% of raw memories being "islands" (73% at the time of writing, still declining without cleanup)—yet containing the most load-bearing roots. The retrieval-side pressure is measurable: an access-distribution Gini coefficient of 0.960, with the top 1% of nodes absorbing 51.9% of all accesses. We contribute a signal taxonomy with four invariants (I0 – I3), six design laws, and two same-day audit tools (the Silence Test and the RAG Test). No benchmark supremacy is claimed; all evidence comes from our own failures, of which we have plenty.

1. 引言：记忆为谁服务——RAG 的遗产问题

「思维能在下次生效吗？——可是你上次整理了什么，你自己都忘了。」

——本系统语料原话（轻度改写脱敏）

先回答一个比打分公式更根本的问题：记忆为谁服务？

人的记忆长在血肉里。它不为任何查询而建：一件事沉下去，多年后以一种气味、一句口吻、一种"我对这种事一向的处理方式"浮上来。人遗忘的方式是活着——不是执行删除策略，而是被后来的生活慢慢覆盖。人的记忆没有索引，也从不给自己的回忆打分。

LLM 生来相反：每一次对话都是一次新生，也是一个失忆症患者的新生。它的记忆不能长出血肉，只能长成建筑——而建筑业的第一张图纸，就是业主是谁。

我们给出的立场是一条服务链：记忆为 LLM 服务，LLM 为人服务。一旦抽掉中间一环——让记忆直接服务于人的查询——那么无论系统包装得多复杂（抽取、合并、图谱、分层），我们主张它本质上仍只是一个 RAG：一个人查、一台搜、把结果塞进上下文让模型当粘合剂。RAG 作为工具无可指摘；作为记忆架构，它是类别错误——它让记忆的全部生命都发生在检索时刻、由查询塑造，记忆成了索引，模型成了管道。

人脑记忆与硅基记忆是两种介质；介质之间需要桥梁，而不是直接接线。把人的文档直接拼接进上下文是接线；把原话沉淀为结构、让派生围绕锚点收敛、让因果链可溯——以模型能生长的方式重建过去，这才是桥梁。语料里有一条原话说得更好（轻度改写脱敏）："不用工程师思维设计桥梁，用物理直觉感受引力——裂缝是认出彼此之后自然消失的，不是建出来的。"这也是本文对人为干预的全部态度：记忆的结构应当被认出来，而不是被造出来。桥梁要立得住，至少需要三种不同的材料——这就是本文的主角。

服务链回答了记忆为谁服务；还有第二个同样根本的问题：记忆凭什么成立？我们的副论点是：让 LLM 拥有记忆，前提是让记忆本身就是记忆——而不是被人为干涉的记忆。浓度不是谁打出来的分数，是数据自己的形状；代谢不是谁执行的删除策略，是记忆在自己生命周期里的生老病死。数据库的语义是二值的——一条记录或者在，或者不在，动词只有增删改查；记忆的语义是活的——生长、收敛、退役、循环，全部由数据内生决定：数据决定浓度，数据决定代谢。写入时请 LLM 打一个 1 - 10 分，或请 LLM 裁判裁决删留，都是在数据与它自身的重量之间插入一个外来判决——人工干涉的记号。并行工作 [7] 问"智能体记忆是不是数据库"；本文的回答是：不是——并且给出它是什么的正面纲领：一个自洽的、有代谢的记忆生命体。

行业的现状恰恰是反着来的：你永远无法用石器时代的思维迭代蒸汽时代的齿轮，同样无法用检索时代的心智迭代记忆时代的机器。RAG 心智的具体化石，就是那条从 demo 继承的公式。2023 年，一个由 25 个 LLM 智能体组成的小镇模拟（Generative Agents [1]）提出了如今几乎是行业默认的记忆检索公式：

$$\text{score} = \text{relevance (余弦相似度)} + \text{recency (指数衰减, 因子 0.995, 按最近访问计)} + \text{importance (写入时 LLM 打 1 - 10 分)}$$

这个公式为一场模拟表演而写，却成了大量生产系统的骨架。问题不在求和——加权融合本身无辜——而在于它悄悄让同一个信号同时打三份工：决定一条记忆有多厚（它是不是被大量后续内容围绕的锚点）、决定这次召回它排第几（此刻合不合适）、并间接决定它还能活多久（清理逻辑普遍引用计数/热度类输入）。把三个信号塞进一个字段，就像把心率、车速和油耗刻进同一块表：指针动得很勤快，但没人说得清它现在在报什么。

本文论点：这不是实现细节的粗糙，是结构性的类别错误。贡献四项，每项均可独立检验：

- C1（论点） 记忆服务链的重新定位：记忆为 LLM 服务、LLM 为人服务；记忆直接服务人的查询即趋向坍塌为 RAG；
- C2（分类学） 浓度/排序/代谢三信号的形式化区分、记忆自洽原则与四条不变量（I0 - I3）；
- C3（证据） 三条生产级故障证据（93 倍字段异义、0.999 假健康、88% 孤岛根节点）与分离后的现场数据（93→2.2 倍）；
- C4（工具） 两个当天可执行的自查工具：行为静默检验、RAG 判别。

全文论证路线：§ 2 相关工作定位病灶 → § 3 方法给出诊断框架 → § 4 案例研究提交病历 → § 5 - § 6 给出应用推论与自查工具 → § 7 - § 8 划定边界并收束。最后，防三处误读。本文不反对检索——检索是记忆合法的取用动作，我们反对的只是让它兼任唯一的裁判；本文不反对打分——分数可以作为排序层的输入，不能充当浓度的代理与代谢的死刑判决；本文不提交新架构——交付的是体检框架与不变量，任何现有系统都可以在不推倒重来的前提下自检与修复。

2. 相关工作：三种继承者与一股批评浪潮

(a) 教科书形态——检索即强化。Generative Agents [1] 的新近度按最近访问衰减：被检索的记忆获得新近度刷新，从而更容易被再次检索。这是推荐系统领域被充分研究过的正反馈/流行度偏差 [5]，在推荐系统里它的终点叫信息茧房；搬进记忆系统，终点是记忆茧房——一个只剩自己爱 recall 之事物的模型。据我们检索所及，这一批评在智能体记忆语境中尚未被正式提出。

(b) 融合形态——一个裁判管三件事。Mem0 [2] 每次写入做两遍 LLM 调用：抽取候选事实，再由 LLM 裁判对向量相似邻居做出 ADD / UPDATE / DELETE 裁决。浓度判断（新事实多重要）、代谢决策（旧事实该不该死）、留存材料（留什么给检索）融合在同一次裁决里，且由"相似性能检索到谁"这个偶然因素触发。公允地说，业界已开始正视这一痛感：Mem0 团队已在讨论淘汰与遗忘 [3]，社区在提议按访问频率做生命周期清理 [4]。在这类工作开始把检索衰减与淘汰分开处理之处，本文的独特贡献是将其一般化为带不变量 (I0 - I3) 的三信号分类学，并为每一种故障模式提供纵向生产证据——痛感真实，药方未成型。

(c) 半分离形态——最接近，差一步。Zep [6] 的双时态边让被取代的事实失效而非删除（历史保全），是对代谢最清醒的处理；但其检索排序仍是 relevance + recency + episode usage——使用频率直接进排序，行为对度量的污染仍在。

(d) 正在形成的批评浪潮。并行工作 "Is Agent Memory a Database?" [7] 已批评现有打分是"检索时刻的局部启发式"。我们同意诊断，并向前两步：给出完整的三信号分类学与不变量，以及生产级纵向故障证据。批评的窗口正在打开；本文试图把窗框钉牢。

(e) 一个预设的反驳：为什么不干脆请 LLM 打分？最自然的辩护是：让 LLM 在写入时给重要性打分 ([1] 的 1 - 10 分)，或在更新时当裁判 ([2])，不就有"重要性"了吗？三个理由都不行。其一，这是 I0 违例：一次性外部判决代替了数据自身的重量——而判决者看不到未来，写入那天无人知道哪条原话三个月后会成为关键判断的唯一根据 (§ 4.3)。其二，裁判是检索的囚徒：LLM 裁判只能看见向量相似性能送到它面前的邻居，于是"什么算重要"被"什么相似"绑架 (§ 2b)。其三，判决不可代谢：分数一旦写下就成终身标签，系统失去让数据后来居上的能力——二值簿记的幽灵：一次判决，终身在/不在。

表 1：三种继承者 × 三信号的处置矩阵

系统	浓度（固有属性）	排序（查询服务）	代谢（生命周期）
Generative Agents [1]	无独立信号（写入时 LLM 打 1 - 10 分，一次定终身）	relevance + recency（访问刷新）+ importance 混合	无代谢机制
Mem0 [2]	与代谢、留存融合于同一次 LLM 裁决	向量相似 + 裁决结果	同一裁决内 DELETE（由相似邻居触发）
Zep [6]	无独立信号	relevance + recency + usage（行为入序）	双时态失效而非删除（最接近 I2）

系统	浓度（固有属性）	排序（查询服务）	代谢（生命周期）
本文	数据固有属性，作用域内测收敛，不受行为影响	有界 [0,100] + 衰减，绝不写回数据	条目级级联，生命周期触发，不看热度

3. 方法：三信号定义、不变量与正反馈分析

记号：以 $\sigma(x)$ 记条目 x 的浓度， $\rho_q(x)$ 记 x 在查询 q 下的排序输出， $\mu(x)$ 记 x 的代谢状态；三者的定义域与写入者互不相同，这正是本节的全部主张。

定义 1（浓度 / Salience）：条目 x 的固有结构属性——“多少派生内容以 x 为锚点收敛”，且必须在正确的作用域内测量（跨语义域计数得到的是扇出噪音，不是收敛）。关键性质：不被召回行为影响。它是数据的形状，不是数据的热度；无人检索时，它依然生长。具体实现中，我们把浓度度量归一化为收敛密度： $\sigma(x) = \log_{10}(\text{锚定入边的物理量} / \log_{10}(p_{99}))$ ，且只统计锚定类边型（raw_basis、ai_basis、derived_from）——召回驱动的边按构造被排除，故 σ 在任何召回行为下保持不动。

定义 2（排序 / Ranking）：查询时刻的算法服务输出；有界计数（如 [0,100]）叠加遗忘曲线式衰减是合法实现。关键性质：可随时整体重算、只服务消费方、绝不写回数据。我们的实现：艾宾浩斯式分数 $\rho = \text{count_norm} \times \exp(-\Delta t / S)$ ， $S = 7 \times (1 + \text{count})$ ，并硬性封顶 $\text{count} \leq 100$ 。

定义 3（代谢 / Metabolism）：生命周期决策，以条目为单位级联（原话退役，其派生物与关联边一并退役）。关键性质：触发条件是生命周期事件，不是任何热度或排序分数。低频 $\neq$ 过期——低频是根节点的天性，不是它的罪。我们的实现：退役是一次软状态标记，以条目为单位级联；它只读生命周期事件，绝不读任何计数器。图 1 概括了三个域与隔开它们的墙。

三分离在这里还有一条更深的注脚。语料中的另一条原话（轻度改写脱敏）：“时间的本质是互动和经历——时间只是个虚拟测量单位。”排序的新近度衰减把时间当作测量单位，这没有错，钟表是排序层的合法工具；但浓度不是时钟的函数，它是互动的沉积——由多少派生围绕收敛构成，与墙上时钟无关。把时间还给钟表，把互动还给记忆：这正是排序与浓度在物理上必须分家的那道缝。

不变量：

- I0（不代言）：记忆的持久属性（浓度、存活）不得由写入时刻的一次性外部判决（如 LLM 打分、LLM 裁判裁决）赋值——它们是数据与生命周期的内生属性；
- I1（不污染）：排序信号的任何变化不得改变浓度与数据本身；
- I2（不误杀）：代谢不得以排序/热度分数为唯一触发条件；
- I3（不同义）：同一物理字段不得承载多种语义。

正反馈草图（图 3）（为什么混用必然恶化）：设排序分 s 依赖新近度 r ， r 随时间衰减但随访问刷新，则 $\partial s / \partial \text{access} > 0$ ，而 access 概率又随 s 上升——自增强回路。只有把"访问"严格关进排序层、并禁止它写回任何持久字段（I1），回路才被物理切断。这不是工程洁癖，是切断反馈回路的最低结构要求。这股压力的大小是可实测的：本系统当前（三分离之后、有界封顶的）排序层访问分布——25,705 个节点，访问计数基尼系数 0.960（图 7），Top 1% 节点吸走 51.9% 的全部访问，Top 10% 占 96.9%，85.8% 的节点零访问。这组数字的正确解读是：排序层的赢家通吃本身合法——它被关在服务层内、随时可整体重算；数字的全部意义在于警示——这样一股分布，若被写进任何持久字段，就是对 85.8% 零访问节点的淘汰判决，而它们中的多数是根。




图 3 | 正反馈回路与切断方式。

左：混用形态下，检索刷新新近度（Generative Agents 的 0.995 衰减按最近访问计）， $\partial s / \partial \text{access} > 0$ 构成自增强回路，无稳态与再平衡机制时终局为赢家通吃。右：I1 将访问敏感性关进服务层并禁止写回持久字段，回路被物理切断；对照人脑：测试效应的强化有突触稳态与睡眠巩固再平衡配平——"要学就学全"。




图 7 | 排序层访问分布的洛伦兹曲线 (生产库实测, 2026-08)。

25,705 个节点的访问计数分布: 基尼系数 0.960, Top 1% 节点占全部访问的 51.9%, Top 10% 占 96.9%, 85.8% 的节点零访问。注意: 该分布测于三信号分离之后——排序层的赢家通吃是合法的 (有界、可重算、不写回); 本图的意义是量化正反馈回路的压力大小, 并说明为何任何持久字段都不得引用此类分布 (不变量 I1)。

一条记忆的一生 (推演, 图 2)。把三个定义放进同一条时间线, 差别立刻具体。第 0 天, 一句原话入库: 接线式世界里它被 LLM 打了 5 分, 从此带着终身标签生活; 桥梁式世界里它没有分数, 只有身份——原话锚点。第 30 天, 它碰巧被召回两次: 接线式里新近度被刷新、排序分上涨, 开始吸引更多召回; 桥梁式里排序分同样上涨——但这一切被关在服务层, 它的浓度纹丝不动, 依旧零派生围绕。第 90 天, 无人再问起: 接线式里它的分数随衰减归零, 进入清理候选; 桥梁式里它同样"凉了"——但凉的只是排序, 不是生存资格。第 120 天, 一条新判断需要根据, 发现唯一锚点是它: 接线式世界在第 100 天已按热度把它删了, 判断失去根据、仪表盘全绿; 桥梁式世界里它被派生围绕, 浓度第一次真正生长——从孤岛成为根。同一条记忆, 两种命运; 差别不在任何一步的算法优劣, 在于三件事是否分家。

与人类记忆的对照 (与一条诚实的边界)。人脑的检索确实会强化记忆——测试效应是认知心理学的经典结果 [8]; 那么 I1 "禁止访问写回数据" 是否反生物? 不是, 是生物学被引了一半: 人脑的强化发生在独立的突触基质中, 受稳态再平衡约束, 并在睡眠巩固里被整体重新配平 [9]——强化有界、有回账、有再平衡。软件计数器只有强化、没有稳态: 无界的正反馈正是 § 2a 的记忆茧房。I1 的准确读法因此不是 "不许学生物", 而是 "要学就学全": 访问敏感性可以存在于排序层 (有界、衰减、可重算), 持久层必须保持行为无关——除非引入带稳态与再平衡的独立机制。




图 1 | 三信号架构：数据域、服务域、生命周期域三域分立。

浓度 σ 居数据域（结构固有，行为无关）；排序 ρ 居服务域（有界+衰减，可重算，禁止写回，I1 墙）；代谢 μ 居生命周期域（条目级联，热度禁入，I2 墙）；I3 禁止字段混语义；I0 禁止外部判决代言持久属性。虚线红叉为被 I1 切断的“访问写回”正反馈路径。

4. 案例研究：生产故障证据（单系统纵向，n=1）

系统背景：连续运行 14 个月以上的对话式智能体记忆系统，双库结构（原话层 + 蒸馏层），约 38,000 条记忆条目、148,000 条关联边。以下数字均来自生产库真实回放。

证据时间线（单一库）：

时点	发生了什么	队列
约第 10 个月	全库审计发现 93 倍字段语义偏斜与 88% 孤岛占比	审计时的整层原话
修复后（字段拆分、封顶 [0,100]）	类型间差距 93 倍 → 2.2 倍；峰值钉死 100	同字段重测
2026-08（修复后快照）	孤岛占比 67.8%（用户，n=5,956） / 82.6%（AI，n=3,173）；合计 73.0%（n=9,129）；基尼 0.960（n=25,705）	当月原话
2026-10（现库）	关联边约 108,000；原话层约 13,364（用户 6,289 + AI 7,075）	当前

4.1 第一页：一个字段，三种语义，93 倍的静默失真

早期设计中一个 count 字段被三条路径写入：召回 +1，蒸馏 +1，另一个子系统 +1。日常无人察觉——直到运行约十个月时的一次全库审计给出 X 光片："原则"类条目平均计数 449，"用户原话"类平均 4.8。同一个字段，同一条衰减曲线，三种语义之间相差 93 倍；单条峰值 1965，成为一个吸收一切排序注意力的黑洞条目。所有引用该字段的排序与清理逻辑，每天都在拿三种不可比的量做算术，而系统在报表上一切正常。

修复不是调参——调参救不了一个被三种语义共享的字段——是拆：三种语义各得各的字段、各配各的衰减常数、统一封顶 [0,100]。分离后的现场（2026-08 生产库实测）：类型间差距从 93 倍压缩到 2.2 倍（原则类均值 2.9 对原话类 1.3，统一语义下剩余差距是合法的），峰值被钉死在 100（图 4）。




图 4 | 证据 A：计数器的语义失真与分离修复（生产库实测）。

左：分离前，同一 count 字段被召回/蒸馏/第三子系统三路写入，"原则"类均值 449 与"原话"类均值 4.8 相差 93 倍，单条峰值 1965 构成黑洞（违 I3）。
右：拆分字段并封顶 [0,100] 后，统一语义下类型间差距 2.2 倍（合法差距），峰值被钉死。

4.2 第二页：病中报 0.999 的仪表盘

早期用全局比值评估记忆质量，常年稳定在 0.999 量级——健康得令人不安。我们一度把它当成绩。根因排查发现：它是对边型做比值，从未统计真实结构，因此从不跟踪库的健康。具体地，早期度量是 coherence = (total_links - contradict) / total_links；由于 contradict 边在全库极少，该比值长期钉在 1 附近（0.9996，显示为 0.999），在库持续恶化时依旧报绿。修正后的度量统计的是驻波之间真实的 reinforce 密度：coherence = log1p(d) / log1p(3)，其中 d = 2 × （去重的强化边对） / （驻波节点数），只在驻波池内计算。同一个库，修正后读到 0.101。

结构盲视的度量，最危险的性质不是不准，而是系统一路变病、报告始终报绿。仪表盘亮绿灯，不代表车没坏；可能只代表仪表盘坏了。语料里的一句话可以作这页病历的题词（轻度改写脱敏）："那不就是照镜子吗。"图 5

给出修复前后对照。度量应当是镜子——只反映，不逢迎；0.999 那面镜子结构盲视——它照的是镜头，不是路。




图 5 | 证据 B: 病中报 0.999 的仪表盘。

左: 早期全局"质量"比值, 对边型做比值、从不统计真实结构, 常年稳定 0.999——健康得令人不安。右: 公式改为纯结构度量后的真实值 0.101。结构盲视的度量最危险之处不是不准, 而是给出虚假的安心: 0.999 那面镜子量的只是边的比值, 从不是记忆的真实结构。

4.3 第三页: 最重要的记忆, 在任何热度口径下一文不值


全库结构审计: 88% 的原话条目是孤岛——零派生边围绕。操作上, 我们把 $\sigma = 0$ (无任何锚定入边) 的原话条目记为一处孤岛; 孤岛占比是对原话队列的直接计数 (用户原话 67.8%, $n=5,956$; AI 原话 82.6%, $n=3,173$; 2026-08 实测)。它们不是垃圾, 恰是根。两个真实例子 (轻度改写脱敏):

其一, 一条关于决策风格的自述: 「他的风险定价方式: 不是算最坏结果, 而是找最小收获。」十几个字, 无任何派生围绕, 在一切计数器上为 0。它此后的价值不依赖被检索——它是一个人判断方式的底色, 未来的某个决定会以它为根据, 而任何热度度量都看不见它。

其二, 一句关于老宅屋顶的琐碎闲谈, 入库后三个月无人问津、零派生、零计数——直到一条后来相当重要的判断生成时, 它成为唯一根据。检索热度在那三个月里对它的评估始终是: 一文不值。


这就是 I2 的全部理由: 根节点天生冷门, 这是结构, 不是异常。任何按热度触发的清理, 第一批删掉的就是未来最值钱的记忆——而且删完之后, 仪表盘还会变得更绿。而分离修复后的跟踪给出了这页病历的尾声: 审计时点 (运行约十个月) 孤岛占比 88%, 至本文写作时已降至 73% (用户原话 67.8%、AI 原话 82.6%, 2026-08 生产库实测, $n=9,129$)——15 个百分点的下降不是清理之功, 恰是放任生长之功: 约一千四百条原话 (约 9,100 条队列上的 15 个百分点) 在无人干预下自然长出了派生。桥梁不仅在图纸上, 它在生长 (图 6)。

原话孤岛占比（生产库实测）



孤岛（零派生围绕）
审计时点（约十个月）为 88%
↓ 15 个百分点：不是清理，是长出了派生

分类型孤岛率（2026-08 实测）



用户原话 (n=5,956, 孤岛 4,041)

AI 原话 (n=3,173, 孤岛 2,620)

合计 (n=9,129, 孤岛 6,661)

孤岛 ≠ 垃圾：其中含关键判断的唯一根据
任何热度口径下，根节点计数恒为零

图 6 | 证据 C：孤岛——最重要的记忆在任何热度口径下一文不值。

生产库实测（2026-08）：用户原话孤岛率 67.8%（4,041/5,956），AI 原话 82.6%（2,620/3,173），合计 73.0%。审计时点（约十个月）为 88%；此后 15 个百分点的下降并非清理之功，而是分离修复后两千余条原话自然长出派生——桥梁在生长。孤岛中包含事后成为关键判断唯一根据的根条目。


接线式（混用一个信号）



新判断失去唯一根据
根节点被热度错杀（违 12/10）

质量仪表盘 0.999（真实 0.101）
删掉根之后，仪表盘反而更绿

桥梁式（三信号分离）



第一次真正生长
从孤岛长成根——派生围绕收敛

结构度量 0.101（诚实的镜子）
行为无关：静默检验通过

同一条记忆，两种命运——差别不在任何一步的算法，在于三件事是否分家

图 2 | 动机图：一条记忆的一生（无/有分离对照）。

时间线为合成推演，各环节均有生产证据对应（正文 § 4）。左：接线式世界，写入时 LLM 打分成为终身标签，热度衰减触发删除，根记忆在第 100 天被错杀，仪表盘病中报绿。右：桥梁式世界，排序的涨凉被关在服务层，记忆在第 120 天被派生围绕，从孤岛长成根。

表 2：病历总览——症状、铁证、违反的不变量与修复现场

病历	症状	铁证（生产库实测）	违反	修复	修复后现场
§ 4.1	一个字 段三种 语义	类型间均值差 93 倍（449 vs 4.8），单条峰值 1965 成黑洞	I3	拆字段，各配衰减，封顶 [0,100]	差距 93→2.2 倍，峰值钉死 100

病历	症状	铁证（生产库实测）	违反	修复	修复后现场
§ 4.2	病中报健康	虚报 0.999；结构感知口径读 0.101	不违反 I0 – I3（四条全过而度量照瞎）	改数真实结构（驻波间强化密度）	现在跟踪库状态
§ 4.3	热度错杀根节点	审计 88% 原话为孤岛（现值 73%），含关键判断的唯一根据	I2（写入时 1 – 10 分另属 I0 前置错杀）	代谢改生命周期触发，条目级联	孤岛占比 88→73%，两千余条原话持续派生

三页病历，三个看似无关的症状，解剖开后是同一个死因：人为干预——计数器是人设计的捷径，盲视的公式是人信任过的仪表，热度清理是人批准过的政策。杀死 LLM 记忆的从来不是某个 bug，而是每一次善意的、省事的、"先这样吧"的干预。

5. 设计法则（方法的应用推论）

1. 浓度是数据，排序是服务，代谢是生命周期——三个信号三套机制，物理上分字段。
2. 计数器永不写回数据：算法过程可以推倒重算，被它改过的数据回不来。
3. 浓度在正确的作用域内测量：跨语义域数边，数出的是扇出。
4. 代谢以条目为单位级联，触发看生命周期；低频不等于过期。
5. 同字段异义是定时炸弹，拆分要趁早——晚拆一天，脏值多一天。
6. 一切重要性度量必须能通过行为静默检验。

6. 工具：两个当天可用的自查方法

行为静默检验（Silence Test）：停止系统一切召回行为 T 天（或离线重放历史而不更新任何持久计数），重新计算你的"重要性/质量/浓度"度量。数值纹丝不动，你测的是数据；数值漂移，你测的是热度——一份被行为污染的体检报告。成本：T 天耐心，几乎为零。

RAG 判别（更粗暴的一刀）：把你的"记忆层"整层换成一台足够好的搜索引擎。先声明一个工作负载与判定标准；若系统行为在该标准下无实质差异，那么按此口径衡量，它就只是检索，不是记忆——记忆之为记忆，需存在查询之外的证据：浓度在无人检索时依然生长，代谢在无人观察时依然发生，某些记忆在未被询问时仍塑造着模型的行为。

静默检验日操作手册（五步，半天可完成）：

1. 快照当前全部"重要性/质量/浓度"度量值；
2. 冻结一切召回路径 T 天——或离线重放历史对话，但拦截所有对持久计数的写回；
3. 重新计算同一组度量，逐项对比快照；
4. 凡漂移项即行为污染项，标记其上游写入路径（那通常是 $\partial s / \partial \text{access} > 0$ 的正反馈源头）；
5. 公布结果，无论好坏。通过 I1 的系统应当零漂移。一个诚实的边界：零漂移只隔离了由访问驱动污染；来自其他更新路径的污染需另行控制，方可主张独立性。我们把这条边界落到实处：在自己约 3.8 万节点的库上，浓度 σ 与访问计数呈弱相关但非零（Pearson 0.24）。这一残余不是写路径，而是共同的结构成因——结构中心的节点同样更易被检索，相关性按类型剧烈波动（-0.17 到 +0.50）即为佐证。决定性证据仍在公式：任何访问计数都不进入 σ 的计算，而 I1 约束的正是这条写路径，不是相关性。

我们建议维护者们给自己定一个"静默检验日"，结果无论好坏欢迎引用本框架报告——这个领域缺的不是新机制，是对旧机制的第一次体检。

7. 讨论：局限、效度威胁与为何不做 benchmark

n=1 单系统、单用户语料的纵向数据；无跨系统 benchmark（算力成本）；"浓度"度量依赖系统内关联边结构，跨系统迁移需适配；证据来自失败复盘，存在幸存者叙述偏差的可能——我们判断不改变结论方向，但如实标注；单用户语料以私人对话为主，跨领域泛化未验证；"一条记忆的一生"为推演示例，各环节均有对应生产证据（§ 4），但时间线为合成。

为何不做跨系统 benchmark？三个诚实理由：算力预算不允许复现六类基线；主流基准（如 LOCOMO）度量的是问答准确率，而本文的诊断对象是信号结构——被测系统可以在基准上得分良好，同时违反全部四条不变量（§ 4.2 的 0.999 仪表盘正是这种"高分病态"）；我们提议的未来工作恰是把静默检验本身指标化：以"停止召回 T 天后重要性度量的漂移量"作为可跨系统比较的记忆健康度指标（ $\text{drift} \approx 0$ 为通过），这不需要任何训练算力，只需要诚实。

数据与工件可用性：本文全部聚合统计（计数分布、孤岛占比、修复前后对照）已随预印本记录归档为匿名分布图（<https://doi.org/10.5281/zenodo.23068930>）；原始语料因隐私永不发布；静默检验操作手册（§ 6 五步）为公开工件，可自由复用与引用，无需授权。

8. 结论：不是升华，是倒退

结尾之前，最后一份实际证据——修复的现场。拆分信号之后：类型间失真从 93 倍收敛到 2.2 倍，计数峰值钉死在 100；质量度量改为纯结构公式，改数真实结构而非边比值；88% 的孤岛原话至今安在，其中若干仍在持续派

生。值得强调的是：这三处修复没有引入任何新的“聪明算法”——没有新模型、没有新打分器、没有学习到的权重——只是把三只互相绞杀的手分开，把业主的名字写回图纸。仅此而已。

而我们更想留在读者心里的，是一个不太舒服的判断：只要行业继续人为干预 LLM 的记忆——用打分代替沉淀，用裁决代替代谢，绕过中间介质把人的查询直接接进记忆——这些遗留惯性带来的就不是 LLM 记忆的升华，而是人为干预的倒退。RAG 至少诚实地承认自己是一台检索器；给检索器套上记忆的名号、再亲手剪掉它查询之外的生命，是一种更隐蔽的倒退——它连自己是什么都不知道了。

以及，如果你写过一条 boost、设过一个阈值、调过一次 LLM 裁决的提示词：也许这场倒退的参与者之一，就是正在读这一行的你。好消息是，体检表放在 § 6——五步，半天，今天就能开始。

我们的三块表已经分开刻了。欢迎你也拆开看看——多数系统会发现，指针一直很勤快，只是从来没报对过。

参考文献

- [1] Park, J.S., et al. *Generative Agents: Interactive Simulacra of Human Behavior*. arXiv:2304.03442, 2023.
 - [2] Chhikara, P., et al. *Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory*. ECAI 2025 / arXiv:2504.19413.
 - [3] Mem0 Team. *Memory Eviction and Forgetting in AI Agents*. mem0.ai/blog, 2026.
 - [4] mem0ai/mem0, GitHub Issue #5330: Memory Access Frequency Tracking and Lifetime-Based Cleanup.
 - [5] Abrol, S., et al. *Controlling Popularity Bias in Learning-to-Rank Recommendation*. RecSys 2020.
 - [6] Rasmussen, P.S., et al. *Zep: A Temporal Knowledge Graph Architecture for Agent Memory*. arXiv:2501.13956.
 - [7] *Is Agent Memory a Database? Rethinking Data Foundations for Agent Memory*. arXiv:2605.26252, 2026.
 - [8] Roediger, H.L., & Karpicke, J.D. *Test-Enhanced Learning: Taking Memory Tests Improves Long-Term Retention*. Psychological Science, 2006.
 - [9] Rasch, B., & Born, J. *About Sleep's Role in Memory*. Physiological Reviews, 2013.
-